

Laboratorium strategii MNQ

Plan operacyjny, specyfikacja techniczna, metodologia badawcza i katalog hipotez dla systematycznego wynalezienia oryginalnej strategii na kontrakcie Micro E-mini Nasdaq-100 — od surowych danych do zweryfikowanej przewagi statystycznej.

Data	Repozytorium	Branch	Instrument	Status
31 lipca 2026	lippaol-art/G	claude/financial-market-strategy-8mb1y1	MNQ (CME Globex)	Po 4 audytach zewnętrznych

Spis treści

1	Streszczenie wykonawcze
2	Filozofia badawcza — skąd naprawdę bierze się przewaga
3	Instrument: pełna specyfikacja MNQ i anatomia doby handlowej
4	Architektura danych
5	Silnik backtestowy — specyfikacja techniczna
6	Metryki i aparat statystyczny
7	Framework walidacji
8	Fabryka hipotez — proces
9	Katalog hipotez: benchmarki, przeformułowania, kandydaci
10	Zarządzanie ryzykiem
11	Paper trading i architektura live
12	Harmonogram: tygodnie 1-12
13	Rejestr ryzyk projektu
14	Zarządzanie projektem i ciągłość między sesjami
15	Etyka, ograniczenia i uczciwość intelektualna
16	Następne kroki
A	Aneks A — Wzory matematyczne
B	Aneks B — Karta kontraktu MNQ i kalendarz rolowań 2026-2027
C	Aneks C — Kalendarz zdarzeń makro i sezonów wyników
D	Aneks D — Szablony dokumentów roboczych
E	Aneks E — Słownik pojęć PL/EN
—	Changelog: wersja 1.0 → 1.1, co zmieniły audyty

Streszczenie wykonawcze

1.1. Misja

Celem projektu „G” jest **wynalezienie, zweryfikowanie i wdrożenie oryginalnej strategii transakcyjnej** na kontrakcie Micro E-mini Nasdaq-100 (MNQ), przy użyciu trzech klas informacji: świec (OHLCV), wskaźników pochodnych od ceny oraz danych o zdarzeniach makroekonomicznych. Projekt prowadzony jest przez agenta (Claude) działającego w repozytorium `lippaol-art/G`, które pełni rolę laboratorium badawczego: przechowuje kod, dane, rejestr hipotez, raporty walidacyjne i dziennik decyzji. Horyzont projektu to miesiące, nie dni — i taka jest też konstrukcja tego dokumentu: ma służyć jako punkt odniesienia przez cały czas trwania badań.

Fundamentalne założenie metodologiczne brzmi: **pomysł na strategię jest tani; drogi jest dowód, że nie jest przypadkiem**. Dlatego zdecydowana większość tego dokumentu nie opisuje „setupów”, lecz aparat, który pozwala odróżnić prawdziwą przewagę statystyczną od szumu: silnik backtestowy bez przecieków informacji, realny model kosztów, walidację walk-forward, testy Monte Carlo i poprawkę na wielokrotne testowanie (Deflated Sharpe Ratio). To jest dokładnie ten aparat, którego brak zabija ponad 90% amatorskich prób budowy strategii.

1.2. Definicja oryginalności

CO ZNACZY „ORYGINALNA STRATEGIA” W TYM PROJEKCIE

Strategia zbudowana **od zera z hipotez strukturalnych** — o mikrostrukturze sesji MNQ, reżimach zmienności i zachowaniu rynku wokół zdarzeń — z własną parametryzacją, własnymi definicjami reżimów i własnymi filtrami. Nie kopiujemy żadnego gotowego setupu z internetu. Uczciwe zastrzeżenie: nie da się formalnie udowodnić, że jakaś reguła „nie istnieje nigdzie w internecie” — przestrzeń publikacji jest nieprzeszukiwalna w całości. Da się natomiast **zagwarantować proces**: każda reguła jest wywiedziona z naszych własnych badań statystycznych na naszych danych, a oryginalność egzekwujemy konstrukcyjnie — przez łączenie minimum dwóch niezależnych warunków (struktura sesji × reżim zmienności × kontekst zdarzeń) i przez własne, niestandardowe definicje operacyjne każdego z nich. Rozdział 8.4 podaje pełne reguły egzekwowania oryginalności.

1.3. Twarde progi sukcesu — system dwustopniowy

Wersja 1.0 tego dokumentu zawierała jedną listę progów. Audyt statystyczny wykazał, że była ona **matematycznie nieprzechodnia**: wymaganie $\text{Sharpe} \geq 0.8$ przy jednoczesnym $\text{DSR} \geq 0.95$ jest nieosiągalne przy realnej długości danych i jakiegokolwiek sensownej liczbie prób (dowód liczbowy w 6.5). To nie była usterka zapisu, lecz treść *False Strategy Theorem*: przy ograniczonej historii i wielu próbach umiarkowanej przewagi po prostu **nie da się** statystycznie certyfikować.

Rozwiązanie nie polega na obniżeniu poprzeczki, lecz na nazwaniu **dwóch różnych poprzeczek i ich konsekwencji**:

Poziom	Wymagania	Co uprawnia
Tier 1 OBIECUJĄCA	Wszystkie kryteria z tabeli niżej <i>poza</i> DSR: liczba transakcji, PF, Sharpe ≥ 0.8 , stabilność, koncentracja, plateau, PBO, transfer, stress kosztów.	Przejście na forward paper trading — jedyny mechanizm dokładający niezależne dane OOS <i>bez zużywania budżetu prób</i> . To ścieżka awansu, nie poczekalnia.

Tier 2 CERTYFIKOWANA	Wszystko z Tier 1 plus DSR ≥ 0.95 liczone na pełnym zszytym szeregu OOS (backtest + zgromadzony paper).	Wyłącznie ten poziom uprawnia do rozmowy o realnym kapitale (rozdz. 11.4, 16).
Kryterium	Próg	Uzasadnienie
Liczba transakcji out-of-sample	≥ 400 (podłoga) cel: 800+	400 to <i>podłoga bezwzględna</i> , nie „wystarczająca próba” — daje moc testu $\sim 50\%$. Moc 80% wymaga ~ 785 transakcji (wyprowadzenie w 6.4).
Profit factor po realnych kosztach	≥ 1.15	Bufor na degradację live; PF 1.05 w backteście to w praktyce strategia stratna.
Sharpe ratio (OOS, annualizowany)	≥ 0.8	Próg <i>ekonomiczny</i> dla systemu jednoinstrumentowego. Uwaga: próg <i>dowodowy</i> jest wyższy — patrz tabela wykonalności w 6.5.
Stabilność w czasie	zysk w ≥ 3 z 4 ostatnich lat	Chroni przed strategią „z jednego reżimu”.
Koncentracja wyniku	usunięcie 5 najlepszych dni nie zmienia znaku wyniku	Chroni przed strategią „z trzech szczęśliwych dni”.
Plateau parametrów	wynik dodatni w całej siatce $\pm 20\%$ parametrów	Ostry szczyt w przestrzeni parametrów = przeuczenie (rozdz. 7.4).
PBO (Probability of Backtest Overfitting)	< 0.20	Mierzy overfitting <i>procesu selekcji</i> — czego żaden test Monte Carlo nie robi (rozdz. 7.2).
Test SPA Hansena	odrzućenie H_0 przy $\alpha = 0.05$	Czy najlepszy wariant bije zero po uwzględnieniu data-snoopingu w całej puli.
Transfer i podokresy	NQ $\approx 1:1$; ES wyjaśniony mechanizmem	Rozdz. 7.5.
Stress-test kosztów	dodatnia przy 2× poślizgu	Realne wypełnienia bywają gorsze niż modelowe.
Deflated Sharpe Ratio (tylko Tier 2)	DSR ≥ 0.95	Poprawka na liczbę wszystkich przetestowanych wariantów projektu. W v1.0 było tu „DSR > 0 ($p < 0.05$)” — kryterium puste , bo DSR jest prawdopodobieństwem i zawsze przekracza zero.

KONSEKWENCJA, KTÓRĄ TRZEBA PRZYJĄĆ ŚWIADOMIE

Każdy dodatkowy przetestowany wariant podnosi poprzeczkę dla ostatecznego zwycięzcy. Dlatego limit prób na hipotezę wynosi ≤ 10 **wariantów** (nie 30, jak w v1.0), a cztery karty katalogu zostały przeniesione do kategorii benchmarków, które nie zużywają licznika (rozdz. 9). Tabela wykonalności w 6.5 pozwala *przed* startem hipotezy sprawdzić, jaki Sharpe jest przy jej budżecie prób w ogóle certyfikowalny.

1.4. Decyzje podjęte (stan na 31.07.2026)

Obszar	Decyzja
--------	---------

Horyzont strategii	Intraday i swing badane równolegle; świadomie akceptujemy wyższy globalny licznik prób, czyli surowszą poprawkę DSR.
Dane od dnia pierwszego	Wyłącznie realne dane rynkowe; zero syntetycznych placeholderów na żadnym etapie.
Dostawca danych historycznych	Databento (CME Globex MDP 3.0, schemat OHLCV-1m, MNQ + NQ od 2019). Wybór uzasadniony w rozdz. 4.1.
Broker	Interactive Brokers, konto paper, wykonanie przez API (<code>ib_async</code>). Uzasadnienie w rozdz. 11.1.
Kalendarz makro	Własna, timestampowana tabela zdarzeń budowana ze źródeł publicznych (rozdz. 4.5).
Trwałość danych	Oczyszczone dane parquet commitowane do repozytorium (środowisko sesji jest efemeryczne).
Ciągłość projektu	Draft PR jako dziennik, <code>REGISTRY.md</code> jako pamięć instytucjonalna, Routines do cyklicznych przeglądów.
Baza kosztów	1 tick poślizgu na stronę → 2.20 USD round-turn . Konserwatyzm zostaje w stress-teście $\times 2$ jako warunku bramki, nie w bazie (rozdz. 3.2).
Bramka sukcesu	System dwustopniowy PROMISING / CERTIFIED (rozdz. 1.3); limit ≤ 10 wariantów na hipotezę.
Zakres danych K6	Wersja oszczędna: ES z Databento + kwartalne snapshoty wag NDX + ceny after-hours 8 megacapów; SOX zastąpiony proxy z półprzewodników obecnych w NDX (rozdz. 4.7).

Wersja 1.1 dokumentu powstała po czterech niezależnych audytach zewnętrznych (metodologia backtestingu, aparat statystyczny, oryginalność katalogu hipotez, stack techniczny). Pełny wykaz przyjętych i odrzuconych uwag znajduje się w Changelogu na końcu dokumentu.

1.5. Zasada procesu: odrzucenie to wynik

W badaniach kwantytatywnych normalny, poprawny rezultat pracy to **odrzucenie większości hipotez**. Każda odrzucona hipoteza zawęża przestrzeń poszukiwań i produkuje wiedzę: wiemy, gdzie przewagi nie ma i dlaczego. Rejestr hipotez (rozdz. 8.3) wymusza zapisanie przyczyny każdego odrzucenia, a wnioski z odrzuconych hipotez są jawnym wejściem do projektowania kolejnej partii. Projekt nie ma zdefiniowanego „końca po N próbach” — iterujemy do skutku, ale iterujemy *uczciwie*: licznik wszystkich prób rośnie globalnie i zaostrza próg istotności dla każdego kolejnego kandydata. To jedyny znany sposób pogodzenia „próbujemy aż się uda” z rzetelnością statystyczną.

1.6. Mapa dokumentu

Rozdziały 2–3 budują fundament pojęciowy: skąd bierze się przewaga i jak naprawdę wygląda instrument, na którym pracujemy. Rozdziały 4–7 to warstwa inżynierska: dane, silnik, metryki, walidacja — serce projektu. Rozdziały 8–9 to warstwa badawcza: proces generowania hipotez i katalog dwunastu konkretnych kart badawczych, od których zaczynamy. Rozdziały 10–11 opisują ryzyko i przejście do handlu papierowego. Rozdziały 12–16 to zarządzanie: harmonogram, ryzyka projektu, ciągłość, granice etyczne i następne kroki. Aneksy zbierają wzory, specyfikacje, kalendarze i szablony do codziennej pracy.

Filozofia badawcza — skąd naprawdę bierze się przewaga

2.1. Dlaczego wskaźniki nie są przewagą

Wszystkie klasyczne wskaźniki techniczne — RSI, MACD, średnie kroczące, Bollinger Bands, stochastic — są **funkcjami deterministycznymi ceny**. Nie zawierają ani jednego bitu informacji, którego nie ma w samych świecach; są jedynie kompresją albo wygładzeniem tej samej serii danych. Z tego wynikają dwie konsekwencje. Po pierwsze, wskaźnik sam w sobie nie może być źródłem przewagi, bo jest publicznie znaną transformacją publicznie znanych danych, liczoną identycznie przez miliony uczestników rynku od dziesięcioleci. Po drugie — i to jest konstruktywna strona tej obserwacji — wskaźnik może być znakomitą **miernikiem** zjawiska, które przewagę daje. ATR nie jest przewagą, ale jest dobrym miernikiem reżimu zmienności. VWAP nie jest przewagą, ale mierzy średnią cenę zaangażowania kapitału w sesji, wokół której faktycznie pracują algorytmy egzekucyjne instytucji. Różnica między „handluję, bo RSI < 30” a „mierzę odchylenie od VWAP, bo testuję hipotezę o zachowaniu algorytmów egzekucyjnych w niskiej zmienności” jest różnicą między zabobonem a badaniem.

2.2. Sześć klas nieefektywności strukturalnych na MNQ

Przewaga statystyczna może istnieć tylko tam, gdzie istnieje **strukturalny powód**, dla którego ceny nie są w pełni efektywne. Na rynku tak płynnym jak Nasdaq-100 futures te powody muszą być mocne — poniżej sześć klas, wokół których zbudowany jest cały katalog hipotez z rozdziału 9.

Klasa	Mechanizm strukturalny	Dlaczego nie znika
K1. Rytm sesji	Doba MNQ składa się z segmentów o skrajnie różnej płynności i populacji uczestników (Azja, Europa, pre-market, otwarcie RTH, lunch, zamknięcie). Przejścia między segmentami wymuszają przewidywalne zachowania: budowanie pozycji, egzekucję benchmarkową, domykanie ryzyka.	Wynika z geografii i regulacji (godziny sesji kasowej, fixing), nie z „wiedzy tajemnej” — nie może zostać zarbitrażowany do zera, bo jest kosztem prowadzenia biznesu uczestników.
K2. Przymus przepływów	Część wolumenu nie jest „opinią o cenie”, lecz przymusem: rebalancing funduszy na koniec miesiąca/kwartalu, zlecenia MOC, hedging opcyjny wokół OPEX, delewarowanie przy skokach zmienności. Przymusowy przepływ przesuwca cenę niezależnie od wartości.	Przepływy są pochodną struktur produktów (fundusze pasywne, opcje), które rosną, a nie maleją.
K3. Reżimy zmienności	Parametry procesu cenowego (autokorelacja, grubość ogonów, skłonność do kontynuacji vs powrotu) są radykalnie różne w niskiej i wysokiej zmienności. Reguła zyskowna w jednym reżimie bywa stratna w drugim — więc filtr reżimu sam w sobie bywa większą częścią przewagi niż sygnał.	Zmienność klastruje się (fakt empiryczny od dekad); uczestnicy reagują na nią z opóźnieniem wymuszonym przez limity ryzyka.
K4. Mechanika zdarzeń	Wokół publikacji makro (CPI, FOMC, NFP) nie da się wygrać wyścigu o pierwszą reakcję — ale <i>struktura</i> reakcji (rozszerzenie zakresu, częstość fałszywego pierwszego ruchu, tempo stabilizacji) jest zjawiskiem mechanicznym: wynika ze zdejmowania płynności przed publikacją i jej powrotu po niej.	Zdejmowanie kwotowań przed publikacją to racjonalna ochrona market-makerów — jest trwałe, bo jest optymalne.

K5. Poziomy mechaniczne	Poprzednie dzienne high/low, granice zakresu nocnego, VWAP, ceny otwarcia — to punkty, w których realnie skoncentrowane są zlecenia (stop-lossy, take-profits, odniesienia algorytmów). Reakcja ceny na nie jest funkcją mechaniki zleceń, nie sentymentu.	Dopóki ludzie i algorytmy kotwiczą zlecenia o punkty odniesienia, punkty te generują podaż/popyt.
K6. Transmisja międzyrynkowa (dodana w v1.1)	MNQ nie istnieje w izolacji: żyje w sieci powiązanych rynków — $NQ \leftrightarrow MNQ$, $NQ \leftrightarrow ES$, $NQ \leftrightarrow$ półprzewodniki, indeksy $\leftrightarrow$ spółki składowe, wrażliwość na stopy. Informacja przepływa między nimi z opóźnieniami i niedoskonałościami; kontrakt bywa nie- albo przereagowany względem tego, co „powinien” wyceniać z ruchów swoich komponentów.	Wycena koszyka wymaga agregacji wielu strumieni informacji przy różnej płynności każdego z nich. Przestrzeń słabo skomercjalizowana publicznie, bo wymaga łączenia danych z kilku rynków — bariera wejścia, która chroni przewagę.

SKĄD WZIĘŁA SIĘ KLASA K6

Wersja 1.0 dokumentu opisywała wyłącznie mechanizmy *wewnątrz* MNQ (K1–K5). Audyt oryginalności trafnie wskazał, że to systematyczna luka: cała rodzina mechanizmów transmisji, bazy i price discovery została pominięta, mimo że jest naturalnie zgodna z profilem projektu i znacznie słabiej wyeksploatowana publicznie niż rytm sesji czy poziomy referencyjne. Hipotezy H013, H014 i H016 z rozdziału 9 należą do tej klasy.

WNIOSEK KONSTRUKCYJNY

Każda hipoteza w tym projekcie musi wskazywać, z której klasy nieefektywności czerpie i **dlaczego ta nieefektywność miałaby przetrwać**. Hipoteza bez mechanizmu („bo na wykresie to widać”) nie wchodzi do rejestru. To pierwszy filtr jakości — tańszy niż jakikolwiek backtest.

2.3. Falsyfikacjonizm jako metoda pracy

Proces badawczy projektu jest zbudowany na zasadzie falsyfikacji: hipoteza jest wartościowa tylko wtedy, gdy da się wskazać wynik testu, który by ją obalił. Praktycznie oznacza to trzy wymogi. **Po pierwsze**, hipoteza musi być sformułowana w jednym zdaniu przed pierwszym dotknięciem danych — „gdy X, to Y ma dodatnie oczekiwanie w horyzoncie Z” — wraz z warunkiem falsyfikacji zapisanym w karcie hipotezy. **Po drugie**, kolejność badania jest nienaruszalna: najpierw eksploracja rozkładów (czy efekt w ogóle istnieje statystycznie?), dopiero potem reguła handlowa i backtest. Odwrócenie tej kolejności — szukanie reguł, które „działały” — to data mining, który na dostatecznie dużej przestrzeni parametrów *zawsze* coś znajdzie, niezależnie od tego, czy w danych jest jakakolwiek struktura. **Po trzecie**, wynik negatywny jest publikowany w rejestrze z taką samą starannością jak pozytywny, bo chroni przyszłe iteracje przed powtórzeniem tej samej ścieżki.

2.4. Ekonomia procesu: ile hipotez umiera i dlaczego to jest zdrowe

Realistyczna kalibracja oczekiwań, oparta na praktyce zespołów kwantytatywnych: z partii dziesięciu dobrze umotywowanych hipotez zwykle **trzy-cztery** wykazują jakikolwiek efekt w eksploracji rozkładów, **jedna-dwie** przeżywają backtest in-sample z realnymi kosztami, a **zero-jedna** przechodzi pełny walk-forward z poprawką DSR. Oznacza to, że znalezienie jednego zweryfikowanego kandydata może wymagać przetestowania dwudziestu-czterdziestu hipotez, czyli — przy tempie jednej-dwóch hipotez na iterację — kilku miesięcy systematycznej pracy. Ta arytmetyka jest wpisana w harmonogram (rozdz. 12) i w mentalność projektu: *seria odrzuceń nie jest sygnałem, że metoda zawodzi; jest sygnałem, że metoda działa* — filtruje. Zawodzi proces, który akceptuje wszystko.

2.5. Antywzorce — czego ten projekt świadomie nie robi

- **Data mining bez hipotezy.** Przeszukiwanie tysięcy kombinacji wskaźników i parametrów „co działało” gwarantuje znalezienie pięknych krzywych kapitału na szumie. Zakazane; każda reguła musi mieć mechanizm z rozdz. 2.2.
- **Optymalizacja do wyniku.** Dobieranie progów sukcesu, okresów testowych albo filtrów *po* zobaczeniu wyników. Progi z rozdz. 1.3 są zamrożone.
- **Kult wskaźników i guru.** Żadna reguła nie zostaje przyjęta dlatego, że „znana postać tak handluje”. Edukacja tradingowa w internecie cierpi na skrajny survivorship bias — słysząc wyłącznie tych, którym (na razie) wyszło, a rozkład wyników całej populacji jest niewidoczny.
- **Wnioski z małych próbek.** Dwadzieścia transakcji nie mówi nic. Minimalne licznosci są policzone w rozdz. 6.6 i egzekwowane w kodzie.
- **Cicha zmiana reguł w trakcie.** Każda zmiana definicji hipotezy w trakcie badania tworzy nową hipotezę z nowym wpisem w rejestrze i podbija globalny licznik prób. Nie ma „doprecyzowań” bez śladu.
- **Mieszanie badania z przekonaniem.** Kierunkowy pogląd na rynek („Nasdaq musi rosnąć, bo AI”) nie jest wejściem do żadnej reguły. Badamy strukturę, nie prognozujemy przyszłości gospodarki.

2.6. Rola newsów i internetu w tym projekcie

Dane o zdarzeniach pełnią trzy funkcje, w kolejności ważności: **(1) filtr bezpieczeństwa** — okna blackout wokół publikacji wysokiej rangi, w których nie otwieramy nowych pozycji, bo spread i poślizg rosną skokowo; **(2) definicja reżimu** — dni FOMC/CPI/NFP oraz dni wyników big-tech to statystycznie inne rynki i są testowane oddzielnie; **(3) surowiec hipotez** — mechanika reakcji na publikacje (klasa K4) jest jednym z pięciu źródeł pomysłów. Czego *nie* robimy: nie próbujemy „przeczytać newsa szybciej niż rynek” (przegramy z maszynami o rzędy wielkości) ani nie budujemy modeli sentymentu z mediów społecznościowych — to osobna, znacznie trudniejsza dyscyplina o wątpliwym stosunku sygnału do szumu przy retailowym stacku danych.

Instrument: pełna specyfikacja MNQ i anatomia doby handlowej

3.1. Karta kontraktu

Nazwa	Micro E-mini Nasdaq-100 Index Futures
Symbol / giełda	MNQ / CME Globex
Instrument bazowy	Indeks Nasdaq-100 (NDX) — 100 największych niefinansowych spółek Nasdaq
Mnożnik	2 USD × wartość indeksu (przy indeksie ~23 000 pkt nominalna wartość kontraktu ≈ 46 000 USD)
Minimalny krok notowania (tick)	0.25 punktu indeksowego = 0.50 USD
Relacja do NQ (E-mini)	MNQ = 1/10 wielkości NQ (NQ ma mnożnik 20 USD); wspólna książka cenowa co do struktury poziomów, osobna płynność
Miesiące kontraktowe	Cykl kwartalny: marzec (H), czerwiec (M), wrzesień (U), grudzień (Z)
Wygaśnięcie	Trzeci piątek miesiąca kontraktowego, rozliczenie gotówkowe do specjalnego kursu otwarcia (SOQ) na bazie cen otwarcia komponentów indeksu
Godziny handlu	Niedziela 18:00 ET - piątek 17:00 ET, z codzienną przerwą serwisową 17:00–18:00 ET
Sesja RTH (umowna)	9:30–16:00 ET — godziny sesji kasowej akcji; pozostały czas = ETH / overnight
Depozyt (initial margin)	Rzędu 2 000–3 500 USD na kontrakt (zmienny, ustalany przez CME; brokerzy intraday bywają niżsi — nie korzystamy z tego przy sizingu, rozdz. 10)
Limity ruchu	Mechanizm circuit breakers powiązany z rynkiem kasowym (7%/13%/20%) + limity nocne ±5% (price limits ustalane od ceny referencyjnej)

3.2. Koszty transakcyjne — pełny rachunek

Model kosztów jest jednym z najważniejszych elementów całego projektu, bo to on decyduje, czy „statystycznie istotny efekt” jest „handlowalną przewagą”. Składniki dla MNQ:

Składnik	Wartość przyjęta	Komentarz
Prowizja broker + giełda + regulacje	≈ 0.60 USD/stronę → 1.20 USD round-turn	Weryfikacja zewnętrzna potwierdziła ten szacunek: CME exchange fee 0.35 + NFA 0.02 + brokerage ~0.25 = 0.62 USD/stronę (1.24 RT). Konfigurowalne w <code>costs.py</code> .
Poślizg — warunki normalne	1 tick (0.50 USD) na stronę dla zleceń rynkowych	MNQ ma spread zwykle 1 tick w RTH; przecięcie spreadu to minimum realizmu.
Poślizg — otwarcie RTH, duża zmienność	2 ticki na stronę	Ruchliwa książka, kolejka po jednej stronie.
Poślizg — okna zdarzeń (CPI/FOMC/NFP ±)	3–4 ticki na stronę (jeśli w ogóle handlowane)	Spread potrafi rozszerzyć się do kilku ticków; domyślnie blackout.
Poślizg — sesja nocna (Azja)	1–2 ticki na stronę	Cieńsza książka; szczególnie 19:00–02:00 ET.

Rachunek roczny. Koszt bazowy round-turn = prowizja 1.20 + 2 × 1 tick poślizgu (2 × 0.50) = **2.20 USD**. Strategia wykonująca średnio 2 transakcje dziennie przez ~251 dni sesyjnych płaci rocznie ≈ **1 104 USD na kontrakt** samych kosztów. Strategia scalpingowa (10 transakcji dziennie) płaci ≈ **5 522 USD** — czyli przy rachunku 25 000 USD musi wygenerować 22% zwrotu rocznie, zanim zarobi pierwszego dolara. Ten rachunek ustawia całą przestrzeń poszukiwań: **preferujemy strategię o niskiej i średniej częstotliwości** (0.5–3 transakcji dziennie), w których koszt nie pożera struktury zysku, a poślizg jest małym ułamkiem przeciętnego ruchu.

Transakcji dziennie	Koszt roczny (baza 2.20)	Koszt roczny w stress-teście ×2 (4.40 USD RT)
0.5	276 USD	552 USD
2	1 104 USD	2 209 USD
5	2 761 USD	5 522 USD
10	5 522 USD	11 044 USD

GDZIE MIESZKA KONSERWATYZM

Wersja 1.0 podawała tu koszt 3.20 USD RT przy jednoczesnym wzorze „1.20 + 2 × 1 tick”, który daje 2.20 — była to niespójność arytmetyczna wychwycona przez audyt. Poprawka nie polega na wyborze wyższej liczby „dla bezpieczeństwa”: **baza ma odzwierciedlać rzeczywistość** (1 tick to realny spread MNQ w RTH przy 1–5 kontraktach), a margines bezpieczeństwa mieszka w obowiązkowym stress-teście ×2, który jest warunkiem przejścia bramki walidacyjnej (7.6). Wbudowanie bufora w bazę spowodowałoby odrzucanie strategii, które realnie by działały — a stress-test stawałby się wtedy testem 4 ticków, czyli scenariusza nierealistycznego.

3.3. Anatomia doby handlowej MNQ (czas ET)

Segment	Godziny ET	Charakterystyka płynności i zachowania
Otwarcie Globex	18:00–19:00	Cienka książka, reakcja na wydarzenia po zamknięciu (wyniki spółek publikowane ~16:05–17:30!). Gapy i szybkie korekty wyceny; wolumen niski, ale informacyjnie gęsty w dni earnings.
Sesja azjatycka	19:00–02:00	Najniższa płynność doby. Zakresy wąskie, skłonność do dryfu i powrotu do średniej; ruchy kierunkowe zwykle wymagają katalizatora z Azji (Boj, dane z Chin). Poślizg relatywnie największy.
Sesja europejska	02:00–08:30	Płynność rośnie od otwarcia Frankfurtu/Londynu (03:00–04:00). Budowanie pozycji przed danymi USA; zakres nocny zwykle domyka swoje ekstrema w tym oknie.
Pre-market danych	08:30–09:30	Publikacje 08:30 ET (CPI, NFP, PKB) uderzają w rynek jeszcze przed sesją kasową — pełna reakcja futures przy niepełnej płynności. Ostatnia godzina przed otwarciem: pozycjonowanie, częste wygaszanie zmienności ~09:15–09:29.
Otwarcie RTH	09:30–10:30	Najwyższa zmienność i wolumen doby. Aukcja otwarcia akcji, realizacja zleceń nagromadzonych overnight, ustalanie initial balance. Publikacje o 10:00 (ISM, Michigan) dokładają drugi impuls. Najczystsze ruchy kierunkowe dnia — i najdroższe wykonanie.
Środek dnia (lunch)	11:30–13:30	Wyraźny dołek wolumenu i zakresu. Rynek algorytmiczno-egzekucyjny: praca wokół VWAP, mikro-rotacje. Fałszywe wybicia częstsze (brak podążającego wolumenu).

Wczesne popołudnie	13:30–15:00	Powrót aktywności; w dni FOMC decyzja o 14:00 i konferencja 14:30 całkowicie przeobrażają segment. Aukcje obligacji (13:00) potrafią przelewać się na indeksy.
Zamknięcie	15:00–16:00	Drugi szczyt wolumenu doby. Imbalance MOC publikowane od 15:50, rebalancing pasywny, domykanie ryzyka intraday. Skłonność do przyspieszenia trendu dnia albo gwałtownego odwrócenia na imbalance.
Po zamknięciu	16:00–17:00	Wyniki spółek (16:05+), płynność ucieka, ruchy skokowe na pojedynczych zleceniach. Dla nas: strefa zamknięta dla nowych pozycji.

KONSEKWENCJA ARCHITEKTONICZNA

Moduł `sessions.py` traktuje te segmenty jako **pierwszorzędne obiekty analizy**: każda transakcja, każdy rozkład i każdy raport jest rozbijany per segment. Strategia „działająca na MNQ” to w praktyce prawie zawsze strategia działająca w jednym–dwóch segmentach — agregacja po całej dobie zamazuje i przewagę, i jej brak. Granice segmentów są definiowane w czasie ET z pełną obsługą zmian czasu (rozd. 4.4).

3.4. Co naprawdę porusza Nasdaq-100

Nasdaq-100 jest indeksem skrajnie skoncentrowanym: kilka największych spółek technologicznych (NVDA, MSFT, AAPL, AMZN, GOOGL, META, AVGO, TSLA) odpowiada łącznie za około połowę wagi indeksu, a sama trójka NVDA/MSFT/AAPL — za około jedną czwartą. Praktyczne konsekwencje dla projektu: **(1)** dni wyników big-tech są zdarzeniami rangi makro dla MNQ i wchodzi do kalendarza zdarzeń na równi z CPI (hipoteza H009); **(2)** korelacja MNQ z ES (S&P 500) jest wysoka, ale rozjazdy — dni, gdy technologia idzie przeciw szerokiemu rynkowi — to informacja sama w sobie; **(3)** wrażliwość na stopy procentowe (spółki wzrostowe = duracja) czyni publikacje inflacyjne i posiedzenia Fed nieproporcjonalnie ważnymi dla MNQ względem innych indeksów. Nie prognozujemy tych czynników — ale musimy wiedzieć, że istnieją, żeby poprawnie klasyfikować reżimy i nie przypisywać „przewadze” tego, co jest ekspozycją na czynnik.

3.5. Dlaczego MNQ, a nie NQ (albo ES)

- **Granularność ryzyka.** Mnożnik 2 USD/pkt pozwala utrzymać ryzyko pojedynczej transakcji w okolicach 0.25–0.5% na rachunkach rzędu 10–30 tys. USD — na NQ (20 USD/pkt) byłoby to niewykonalne bez zawężania stopów do poziomu szumu.
- **Identyczna struktura informacyjna.** MNQ i NQ śledzą ten sam indeks; badania przeprowadzone na cenach są przenośne, a walidacja krzyżowa NQ↔MNQ jest naturalnym testem odporności (rozd. 7.5).
- **Płynność wystarczająca do skali projektu.** Dzielne wolumeny MNQ idą w setki tysięcy kontraktów; dla 1–5 kontraktów poślizg modelowany w 3.2 jest realistyczny. Problemy płynności NQ vs MNQ zaczynają się przy rozmiarach, które są poza horyzontem tego projektu.
- **Koszty proporcjonalne.** Prowizje mikro są proporcjonalnie wyższe (per dolar ekspozycji) niż na NQ — to świadomie zaakceptowany koszt granularności; model kosztów to uwzględnia.

Architektura danych

4.1. Wybór dostawcy: Databento (i dlaczego nie inni)

Opcja	Zalety	Wady / powód odrzucenia
Databento (wybrane)	Surowe dane prosto z CME MDP 3.0 (dataset GLBX.MDP3, futures CME od 2010; MNQ od 2019-04-14, czyli od startu produktu); jawna metodologia; schematy OHLCV-1m, 1s, trades i MBP; pay-as-you-go bez abonamentu; czyste API Pythona; timestampy giełdowe w nanosekundach.	Wymaga własnego sklejenia kontraktu ciągłego (traktujemy to jako zaletę: pełna kontrola, rozdz. 4.3).
FirstRate Data	Publikuje 3 warianty kontraktu ciągłego (unadjusted / absolute / ratio) oraz serie per kontrakt; NQ M1 od 2008; ~100 USD/rok.	Brak streaming API (tylko pliki), rolowanie nie wg naszej reguły wolumenowej, gorsza audytowalność niż surowe MDP. Dobre jako źródło wtórne do kontroli krzyżowej , słabe jako primary.
Kibot	Pakiet wszystkich futures continuous 1m od 2009, 520 USD jednorazowo; publikowany kalendarz rolowań.	Rolowanie kalendarzowe (nie wolumenowe); mieszana reputacja jakości; dla dwóch symboli drożej i mniej przejrzystość niż Databento.
IQFeed / DTN	Solidny feed z historią.	Abonament ~105 USD/mies. + opłaty giełdowe — nieproporcjonalny do 12-tygodniowej fazy badawczej. Sensowny przy stałym desku live.
Dane z IBKR API	Zero dodatkowego kosztu przy koncie.	Twarde ograniczenie oficjalne: kontrakty wygasłe dostępne tylko do ~2 lat od wygaśnięcia. Plus pacing limits i luki. Nie da się pobrać 2019→dziś.
Darmowe źródła (Yahoo itp.)	Koszt zerowy.	Brak rzetelnego M1 futures, nieznana proveniencja; niedopuszczalne dla wniosków badawczych — zero placeholderów.

Koszt i licencje — stan zweryfikowany

- **Koszt historii:** ~25–60 USD za MNQ + NQ, OHLCV-1m, 2019→dziś (zależnie od tego, czy pobieramy wszystkie nogi kontraktowe). Nowe konto otrzymuje **125 USD kredytów startowych**, więc praktyczny koszt tej fazy wynosi zero. Przed każdym pobraniem obowiązkowo `metadata.get_cost`. Batch download: opłata raz, ponowne pobranie w ciągu 30 dni bezpłatne.
- **Subskrypcja Databento Standard (199 USD/mies.) jest zbędna** — historyczne OHLCV mieści się w warstwie pay-as-you-go.
- **Licencje:** dane historyczne T+1 do backtestu i researchu nie wymagają licencji giełdowej CME. Automatyczny handel na własnym rachunku z wykorzystaniem danych historycznych jest dozwolony; egzekucja idzie przez brokera i to on dostarcza dane live. Redystrybucja na zewnątrz podlega osobnym ograniczeniom — nie dotyczy tego projektu.

PUŁAPKA: CONTINUOUS SYMBOLOGY DATABENTO JEST NIESKORYGOWANE

Symbole typu `MNQ.v.0` zwracają ceny **unadjusted** — Databento nie wykonuje syntetycznego back-adjustmentu. To dobrze współgra z naszym planem własnego sklejania (4.3), ale oznacza bezwzględny zakaz: **nie wolno używać serii continuous „prosto z API” jako podstawy do liczenia P&L punktowego**. Ścieżka obowiązkowa: surowe kontrakty per wygaśnięcie → własne rolowanie wolumenowe → własny back-adjust różnicowy.

Ochrona przed pojedynczym punktem awarii danych

Cała wiedza projektu opiera się na jednym dostawcy — to ryzyko systemowe. Mitygacja: **kontrola krzyżowa jednego pełnego miesiąca danych względem źródła wtórnego** (FirstRate w tej roli), z zapisem wyniku porównania i sum kontrolnych w `manifest.md`. Dodatkowo opcja: zakup 3–6 miesięcy schematu `trades` i samodzielne zbudowanie z niego barów M1 — porównanie z barami dostawcy jest najmocniejszym testem jakości, jaki możemy wykonać, a te same dane posłużą do rozstrzygania spornych barów w silniku (5.4). Uwaga operacyjna: Databento zmienił normalizację GLBX.MDP3 w lipcu 2026 — **datę pobrania i wersję schematu pinujemy w manifeście**, a przy zmianach po stronie dostawcy regenerujemy `data/clean/` od zera.

4.2. Pipeline danych: raw → clean

```
Databento API → data/raw/ (pliki natywne .dbn / .parquet, gitignore)
    |
    ▼ scripts/build_dataset.py
[1] dedup + sortowanie po ts_event
[2] walidacja: monotoniczność czasu, OHLC-spójność ( $L \leq 0, C \leq H$ ), wolumen  $\geq 0$ 
[3] KLASYFIKACJA LUK wg kalendarza sesji CME: expected_gap vs anomaly_gap ◀ nowe w v1.1
[4] mapowanie kontraktów: MNQH5, MNQM5, ... + tabela dat rolowania (wolumenowa)
[5] sklejenie kontraktu ciągłego + back-adjust (rozdz. 4.3)
[6] konwersja stref: przechowujemy UTC, indeksujemy sesję w ET (rozdz. 4.4)
[7] oznaczenia segmentów sesji (kolumna `segment`) i dnia sesyjnego (`trade_date`)
[8] flagi: dst_transition, short_day, days_to_roll, halt_window (2019–2021)
    |
    ▼
data/clean/mnq_1m_cont.parquet (commitowane do repo)
data/clean/nq_1m_cont.parquet (do testów transferu)
data/clean/events.csv (kalendarz zdarzeń, rozdz. 4.5)
data/manifest.md (zakres, wersje, sumy kontrolne)
```

SEMANTYKA OHLCV: BRAK BARA NIE JEST LUKĄ W DANYCH

Dokumentacja Databento stanowi wprost: „*If no trade occurs within the interval, no record is printed.*” Oznacza to, że **brak bara M1 jest poprawnym opisem rynku** (nie było transakcji), a nie defektem feedu. Wersja 1.0 tego dokumentu zakładała ~1380 barów na dzień i traktowałaby każdy brak jako anomalię — sanity-report generowałby fałszywe alarmy w cienkich godzinach sesji azjatyckiej.

Konsekwencje, które muszą być w kodzie:

- Rozróżnienie `expected_gap` (przerwa serwisowa 16:00–17:00 CT, weekend, święto, dzień skrócony, historyczny halt 15:15–15:30 CT do 27.06.2021, brak transakcji w cienkiej godzinie) od `anomaly_gap` (wszystko inne — do ręcznego przejrzenia).
- Forward-fill jest dozwolony dla wskaźników, ale bezwzględnie zakazany dla barów wejścia i stop-lossa.** Wolumen zero oznacza, że nie było gdzie się wykonać — symulowanie transakcji w takim barze produkuje zysk, którego nie dało się zrealizować.
- Kalendarz sesji CME jest osobnym, wersjonowanym artefaktem, nie wnioskowaniem z danych.

Zasada niezmienniczości: pliki w `data/clean/` są **artefaktami wersjonowanymi** — każda regeneracja podbija wpis w `manifest.md` (data, zakres, hash, wersja skryptu). Żaden backtest nie czyta z `raw/`; jedynym wejściem badań jest `clean/`. Dzięki temu każdy wynik w projekcie jest odtwarzalny co do bajta.

4.3. Kontrakt ciągły: rolowanie wolumenowe i back-adjustment

Kontrakty futures wygasają co kwartał; do badań potrzebna jest jedna ciągła seria. Dwie decyzje do podjęcia — obie podejmujemy jawnie:

(a) Kiedy rolować. Rolujemy w dniu, w którym **wolumen kontraktu następnego przewyższa wolumen bieżącego** (mediana z sesji), co dla indeksów wypada zwykle ~8 dni kalendarzowych przed wygaśnięciem (okolice „roll Thursday”). Reguła wolumenowa, nie kalendarzowa — bo odzwierciedla faktyczną migrację płynności, którą handlowalibyśmy live.

(b) Jak skleić poziomy cen. Stosujemy **back-adjustment różnicowy**: w dniu rolowania liczymy spread $S = \text{close}(\text{nowy}) - \text{close}(\text{stary})$ i przesuwamy całą historię wstecz o S . Właściwości: różnice cen (a więc P&L w punktach, ATR, zakresy) są zachowane idealnie — a to na nich pracuje 100% naszych obliczeń; poziomy absolutne sprzed lat stają się umowne (akceptowalne; nigdy nie porównujemy odległych poziomów absolutnych). Alternatywa (ratio-adjust) jest potrzebna tylko przy analizach stóp zwrotu wieloletnich — poza zakresem strategii intraday/swing.

DLACZEGO TO JEST KRYTYCZNE

Nieskorygowane sklejenie pozostawia w serii sztuczne skoki cen w dniach rolowania (contango/backwardation). Strategia „kupuj spadki” przetestowana na takiej serii „zarabia” na lukach, które nigdy nie były handlowalne. To jeden z najczęstszych sposobów, w jaki amatorskie backtesty futures produkują fikcyjne zyski — i pierwszy test jednostkowy silnika (rozdz. 5.6): w serii ciągłej nie może istnieć bar, którego open odbiega od poprzedniego close o spread rolowania.

Rozdzielenie serii: gdzie liczymy co (nowe w v1.1)

Back-adjust przesuwca całą historię sprzed rolowania o stałą wartość. Wewnątrz jednego okresu kontraktowego relacje cenowe są zachowane idealnie — ale **na granicy rolowania poziomy odniesienia sięgające wstecz przestają odpowiadać cenom, które realnie widniały na tablicy**. Trader patrzący w dniu rolowania na poprzednie dzienne maksimum widzi je na nowym kontrakcie, przesunięte o spread względem starego.

Wielkość	Liczona na serii	Uzasadnienie
PDH / PDL / PDC, poziomy międzysesyjne, zakres nocny odnoszony do dnia poprzedniego	surowej (kontrakt aktywny)	To są ceny, przy których realnie stały zlecenia. Na serii skorygowanej rozjeżdżają się w 4 dniach rolowania w roku, generując sygnały wejścia na poziomach, które nie istniały.
VWAP sesyjny, zakres dnia, ATR, wszystkie wskaźniki wewnątrzsesyjne	obojętne	Mieszczą się w całości w jednym kontrakcie; stałe przesunięcie ich nie zmienia. (Audyt sugerował tu szerszą korektę — zawężamy ją do przypadków, w których faktycznie występuje różnica.)
P&L, equity, statystyki zwrotów	ciągłej skorygowanej	Wymaga jednorodnej skali punktowej przez całą historię.

Loader udostępnia obie reprezentacje równoległe (`px_raw` i `px_adj`), a test jednostkowy w 5.6 sprawdza, że funkcje poziomów referencyjnych sięgają wyłącznie do `px_raw`.

4.4. Strefy czasowe i zmiana czasu — pułapki

- **Przechowywanie: wyłącznie UTC.** Każdy bar ma timestamp UTC; kolumny pochodne (`et_time` , `segment` , `trade_date`) są generowane przez konwersję z pełną bazą stref (IANA `America/New_York`).
- **Sesje definiowane w ET, nie w UTC.** Otwarcie RTH to zawsze 9:30 ET — w UTC to 13:30 lub 14:30 zależnie od pory roku. Definicja w UTC rozjeżdża wszystkie statystyki otwarcia dwa razy w roku.
- **Dzień sesyjny ≠ dzień kalendarzowy.** `trade_date` zaczyna się o 18:00 ET dnia poprzedniego (otwarcie Globex). Sesja nocna „poniedziałkowa” zaczyna się w niedzielę wieczorem. Cała agregacja dzienna działa na `trade_date` .
- **Tygodnie przejściowe.** USA i Europa zmieniają czas w różnych tygodniach (marzec/październik-listopad) — przez 1-3 tygodnie w roku relacja między otwarciem Europy a godzinami USA jest przesunięta. Oznaczamy te tygodnie flagą `dst_transition` i traktujemy jako potencjalny czynnik zakłócający w analizach sesji europejskiej.
- **Dni skrócone.** Wigilia, dzień po Świącie Dziękczynienia itd. — wcześniejsze zamknięcia (13:00 ET). Utrzymujemy tabelę dni skróconych i wykluczamy je z analiz segmentu zamknięcia.

4.5. Kalendarz zdarzeń: schemat i budowa

Tabela `events.csv` — jedno zdarzenie na wiersz, timestampy w UTC:

ts_utc,	kind,	rank,	name,	note
2026-07-14T12:30:00Z,	macro,	1,	CPI,	"core m/m 0.3 exp"
2026-07-29T18:00:00Z,	macro,	1,	FOMC_decision,	" "
2026-07-29T18:30:00Z,	macro,	1,	FOMC_presser,	" "
2026-08-07T12:30:00Z,	macro,	1,	NFP,	" "
2026-08-01T20:05:00Z,	earnings,	1,	AAPL,	"after close"
2026-08-15T00:00:00Z,	market,	2,	OPEX,	"3rd Friday"
2026-09-30T00:00:00Z,	market,	2,	quarter_end,	"rebalancing"

Ranga 1 = zdarzenia przebudowujące dobę (CPI, FOMC, NFP, PCE, wyniki top-8 spółek); ranga 2 = zdarzenia strukturalne kalendarza (OPEX, końce miesiąca/kwartalu); ranga 3 = pozostałe publikacje (ISM, Michigan, JOLTS...). Budowa: historyczne daty publikacji rangi 1 są deterministyczne lub archiwalnie dostępne (BLS, Fed, kalendarze publiczne) — scraping + ręczna walidacja wrywkowa 20 losowych wpisów na rok danych. Silnik dostaje funkcje `time_to_event(ts)` i `time_since_event(ts)` — każda hipoteza może warunkować na odległości od zdarzenia.

4.6. Kontrola jakości: sanity-report

Po każdej regeneracji `data/clean/` generowany jest `reports/data_quality.md` :

- liczba barów na dzień sesyjny w czasie — **rozbita na segmenty**, bo oczekiwana liczba barów zależy od płynności segmentu (w RTH bliska 390, w sesji azjatyckiej istotnie niższa i to jest normalne);
- histogram luk z **obowiązkową klasyfikacją każdej luki** na `expected` (przerwa serwisowa, weekend, święto, dzień skrócony, halt 15:15-15:30 CT dla lat 2019-H1 2021, brak transakcji) i `anomaly` — tylko te drugie trafiają do przeglądu;
- udział barów o wolumenie zero w każdym segmencie — kontrola, czy zakaz forward-fill dla barów wykonania jest respektowany;
- rozkład zakresów barów — bary-outliery ($> 0.5\%$ w 1 min) do ręcznego przejrzenia z listą dat;
- weryfikacja krzyżowa: **pełny miesiąc** porównany ze źródłem wtórnym + 10 losowych sesji porównanych z niezależnym wykresem (zgodność ekstremów dnia do 2 ticków);
- ciągłość rolowania: zero skoków open/close w dniach rolowań po adjustmencie;
- rozjazd `px_raw` vs `px_adj` w dniach rolowania — kontrola, że rozdzielenie serii z 4.3 działa;
- pokrycie kalendarza zdarzeń: każdy miesiąc historii musi mieć komplet zdarzeń rangi 1 (CPI×1, NFP×1, FOMC w miesiące posiedzeń);

- metadane: wersja schematu dostawcy, data pobrania, sumy kontrolne — do wykrycia zmian normalizacji po stronie Databento.

4.7. Dane uzupełniające dla klasy K6 (nowe w v1.1)

Hipotezy z klasy transmisji międzyrynkowej (H013, H014, H016) wymagają danych spoza MNQ. Zakres przyjęty świadomie w **wersji oszczędnej** — maksimum możliwości badawczych przy minimum nowych źródeł:

Dane	Źródło	Uwagi i koszt
ES (E-mini S&P 500) M1	Databento GLBX.MDP3	Ta sama rodzina danych, ten sam pipeline i to samo rolowanie — koszt marginalny. Służy zarówno H014, jak i testom transferu z 7.5.
Wagi składników NDX	Publikacje indeksowe, snapshoty kwartalne	Wagi zmieniają się wolno; interpolacja między kwartałami jest wystarczającym przybliżeniem dla sygnału rezydualnego. Rekonstrukcja wstecz od 2019.
Ceny after-hours 8 megacapów	Databento (dane akcyjne)	Jedyny realny nowy koszt. Potrzebne wyłącznie w oknach po publikacji wyników — pobieranie punktowe, nie ciągłe.
Proxy SOX (półprzewodniki)	Koszyk spółek już obecnych w NDX	Zero dodatkowego źródła: NVDA, AVGO, AMD, QCOM, INTC, MU i pokrewne i tak są w zbiorze składników. Własny indeks ważony kapitalizacją zastępuje właściwy SOX.

Kontrola jakości specyficzna dla K6: suma wag składników musi mieścić się w [0.98, 1.02] w każdym snapshocie; ruchy after-hours muszą mieć niezerowy wolumen (inaczej odrzucane); beta względem ES i proxy-SOX estymowana na oknie kroczącym, nie globalnie. Wszystkie serie uzupełniające trafiają do `data/clean/` z osobnymi wpisami w manifeście.

CZEGO ŚWIADOMIE NIE KUPUJEMY

Właściwego indeksu SOX, rentowności Treasuries w wysokiej rozdzielczości ani danych akcyjnych poziomu `trades /MBP` dla składników. Hipoteza **H015 (price discovery NQ→MNQ)** pozostaje z tego powodu *zarejestrowana, ale niebadalna* — na barach M1 wynik lead-lag byłby artefaktem agregacji, nie zjawiskiem rynkowym. Wraca do kolejki, jeśli kiedykolwiek pozyskamy dane tickowe.

Silnik backtestowy — specyfikacja techniczna

5.1. Zasady konstrukcyjne

1. **Event-driven na barach M1.** Silnik iteruje bar po barze; strategia widzi wyłącznie dane do bieżącego bara włącznie. Nie ma żadnej ścieżki API, którą strategia mogłaby zajrzeć w przyszłość — to gwarancja architektoniczna, nie konwencja.
2. **Sygnał na close, wykonanie na open następnego bara.** Domyślny model wykonania; zlecenia stop/limit są dodatkowo symulowane wewnątrzbarowo wg reguł z 5.4.
3. **Konserwatyzm przy niejednoznaczności.** Wszędzie tam, gdzie bar M1 nie rozstrzyga kolejności zdarzeń, wybieramy wariant gorszy dla strategii (5.4). Backtest ma prawo zaniżać wynik; nie ma prawa go zawyżać.
4. **Stan strategii jawny i serializowalny.** Strategia to czysta funkcja `(bar, state) → (orders, state)`; identyczny kod działa w backteście i (docelowo) w pętli live — eliminujemy klasę błędów „w backteście liczyło się inaczej niż live”.
5. **Wszystko konfigurowalne, nic ukrytego.** Koszty, poślizgi, godziny, filtry — jawne parametry z wartościami domyślnymi z tego dokumentu; każdy run zapisuje pełną konfigurację do raportu.

5.2. Kontrakty API modułów

```
# engine/loader.py
def load_continuous(symbol: str, tf: str = "1m") -> pl.DataFrame
    # kolumny: ts_utc, open, high, low, close, volume, et_time, trade_date,
    #         segment, contract, days_to_roll, dst_transition, short_day

# engine/sessions.py
SEGMENTS = ["globex_open", "asia", "europe", "premarket", "rth_open",
            "midday", "afternoon", "close", "after_hours"]
def segment_of(ts_et) -> str
def session_slice(df, trade_date, segment) -> pl.DataFrame

# engine/features.py - wszystkie funkcje przyjmują TYLKO dane historyczne
def atr(df, n) / def vwap_session(df) / def overnight_range(df, trade_date)
def rolling_percentile(series, window, value) -> float # percentyl w oknie
def prev_day_levels(df, trade_date) -> {pdh, pdl, pdc, rth_open}
def time_to_event(ts, events, rank) / def time_since_event(ts, events, rank)

# engine/costs.py
@dataclass CostModel: commission_rt: float = 1.20
def slippage_ticks(segment: str, near_event: bool, vol_regime: str) -> int

# engine/backtest.py
@dataclass Order: side, qty, type("mkt"|"stop"|"limit"), px, sl, tp, tif
@dataclass Fill: ts, px, qty, fees, slippage
def run(df, strategy: Strategy, cost: CostModel, risk: RiskLimits) -> Result
    # Result: trades[], equity_curve, config_snapshot, n_variants_tested

# engine/metrics.py
def summarize(result) -> Metrics # pełny zestaw z rozdz. 6
def breakdown(result, by="year"|"segment"|"regime"|"weekday") -> tabela
```

5.3. Główna pętla — pseudokod

```

for bar in continuous_series:                                # chronologicznie, M1
    # 1. AKTUALIZACJA POZYCJI – wewnątrzbarowe SL/TP (reguły 5.4)
    for pos in open_positions:
        fill = resolve_exits(pos, bar)                        # konserwatywnie
        if fill: close_position(pos, fill, costs(bar))

    # 2. LIMITY RYZYKA – twarde, przed strategią
    if daily_loss_R(trade_date) <= -risk.daily_stop_R: continue
    if in_blackout_window(bar.ts, events):                    continue

    # 3. STRATEGIA – widzi tylko przeszłość
    orders, state = strategy.on_bar(view_until(bar), state)

    # 4. WYKONANIE – na open NASTĘPNEGO bara + poślizg + prowizja
    for o in orders:
        queue_for_next_open(o, slippage_model(bar))

    # 5. KSIĘGOWANIE
    equity.append(mark_to_market(bar.close))
    audit: len(trades), config_hash, global_trial_counter += grid_size

```

5.4. Rozstrzyganie wewnątrzbarowe — pełna tabela reguł

Sytuacja w barze M1	Rozstrzygnięcie
Bar dotyka tylko SL	Wyjście po SL – poślizg (stopy wykonują się gorzej, nigdy lepiej).
Bar dotyka tylko TP (limit)	Wyjście po TP bez poślizgu dodatniego, ale wymagane <i>przebicie</i> ceny limitu o ≥ 1 tick (samo dotknięcie nie gwarantuje wypełnienia w kolejce).
Bar dotyka SL i TP	Rozstrzygane sub-barami 1s (patrz ramka niżej). Fallback bez danych 1s: liczy się SL <i>plus obowiązkowe raportowanie pasma wrażliwości</i> .
Open bara przeskakuje SL (gap)	Wyjście po open bara (nie po cenie SL) – poślizg skalowany wielkością luki : w pierwszych sekundach po otwarciu luką płynność w książce spada niemal do zera, więc realna kara sięga 2-8 ticków ponad cenę open. Model: $\text{slip_gap} = \text{base} + k \cdot \min(\text{gap}/\text{ATR_M1}, 4)$.
Zlecenie stop-entry: open przeskakuje poziom	Wejście po open + poślizg.
Wejście i potencjalne wyjście w tym samym barze	Wyjście dopiero od bara następnego — w barze wejścia znamy tylko fakt wypełnienia, nie trajektorię po nim.
Bar w przerwie serwisowej / poza godzinami strategii	Zlecenia oczekujące zamrożone; pozycje przenoszone z pełnym mark-to-market (ryzyko luki widoczne w equity).
Koniec dnia strategii intraday	Przymusowe zamknięcie po close ostatniego bara okna – poślizg (flat-by rule konfigurowalny per strategia).

ROZSTRZYGANIE BARÓW SPORNYCH — ROZWIĄZANIE HYBRYDOWE (V1.1)

Reguła „przy dotknięciu SL i TP w jednym barze liczy się SL” wydaje się bezpiecznym konserwatyzmem, ale audyt metodologiczny wykazał, że jest **skrzywieniem statystycznym**: im szerszy cel względem stopa, tym częściej bar obejmuje oba poziomy — więc reguła systematycznie i nieproporcjonalnie karze strategię o wysokim stosunku zysku do ryzyka, zaniżając ich win rate i generując fikcyjne obsunięcia.

Rozwiązanie: w momencie wykrycia bara spornego silnik dociąga **60 sub-barów jednosekundowych** (schemat `ohlcv-1s` Databento) wyłącznie dla tej jednej minuty i odtwarza faktyczną chronologię. Nie przeliczamy całej historii w rozdzielczości 1 s — pobieramy punktowo, tylko dla spornych minut, których w całej historii będzie rzędu setek. Koszt obliczeniowy i finansowy: pomijalny.

Fallback (gdy dane 1 s niedostępne dla danego okresu): zachowujemy regułę „SL wygrywa”, ale raport hipotezy **musi** zawierać *pasmo wrażliwości* — wynik przy założeniu „SL wygrywa” i „TP wygrywa” jako dwie osobne liczby. Strategia, która jest dobra tylko przy optymistycznym końcu pasma, nie jest dobra.

Odrzucono alternatywę proponowaną przez audyt (wnioskowanie kolejności z położenia ceny otwarcia względem ekstremów bara) — jest to heurystyka bez walidacji empirycznej, a jej błędy byłyby skorelowane z kierunkiem ruchu, czyli dokładnie tam, gdzie najbardziej szkodzą.

5.5. Model poślizgu

Poślizg bazowy zależy od segmentu sesji, ale **skaluje się dynamicznie zmiennością** — statyczna tabela zaniżałaby koszt dokładnie w tych momentach, w których jest największy:

```
slippage_ticks = base(segment) × clamp( ATR_M1 / median(ATR_M1, 60d), 1.0, 3.0 )
```

Kontekst	base (zlecenie rynkowe / stop)	Uwagi
RTH poza otwarciem, zmienność normalna	1 tick	baza; odpowiada realnej głębokości pierwszego poziomu książki MNQ przy 1–5 kontraktach
Otwarcie RTH (09:30–10:00)	2 ticki	ruchliwa książka
±10 min od zdarzenia rangi 1	4 ticki	domyślnie blackout; wartość dla strategii zdarzeniowych — model ×2 obowiązuje już na etapie in-sample
Azja (19:00–02:00 ET)	2 ticki	cienka książka
Stop przeskoczony luką	base + $k \cdot \min(\text{gap}/\text{ATR_M1}, 4)$	do 8 ticków przy dużych lukach — płynność po otwarciu luką jest bliska zeru
Stress-test (rozdz. 7.6)	× 2 wszystkie powyższe	warunek przejścia bramki walidacyjnej

Model nie korzysta z rzeczywistej szerokości spreadu, bo schemat OHLCV jej nie zawiera; ATR minutowy jest proxy. Gdyby projekt kiedykolwiek pozyskał dane `bbo-1s`, mnożnik zmienności należy zastąpić zmierzonym spreadem — to jedyna zmiana wymagana w tym module.

5.6. Walidacja samego silnika — zanim przetestujemy cokolwiek

Silnik, któremu nie udowodniono poprawności, produkuje śmieci z dokładnością do sześciu miejsc po przecinku. Przed pierwszą hipotezą silnik musi przejść:

1. **Testy jednostkowe** (pytest): rozstrzygnięcia z tabeli 5.4 na spreparowanych barach; poprawność rolowania (test z 4.3); segmenty przy zmianie czasu; naliczanie kosztów; przymusowe zamknięcia; **rozdzielenie serii** — funkcje poziomów referencyjnych nie mogą sięgać do `px_adj`; **zakaz wykonania w barze o wolumenie zero**.
2. **Test zerowej przewagi**. Strategia losowych wejść (moneta, losowy SL/TP) na realnych danych: oczekiwany wynik $\approx -(\text{koszty} \times \text{liczba transakcji})$, rozkład zysków symetryczny przed kosztami. Odchylenie od tego = przeciek informacji w silniku.
3. **Test znanego efektu**. Kup na close RTH, sprzedaj na open RTH (overnight) vs kup na open, sprzedaj na close (intraday) — silnik musi odtworzyć znaną z literatury asymetrię overnight/intraday na indeksach US co do znaku i rzędu wielkości. To nie jest nasza strategia; to linijka do mierzenia, czy silnik mierzy dobrze.
4. **Test symetrii**. Odwrócenie każdej reguły (long↔short) na strategii losowej musi dawać lustrzany wynik przed kosztami.
5. **Test determinizmu**. Dwa uruchomienia z tym samym seedem → bitowo identyczne wyniki (wymóg odtwarzalności).

Metryki i aparat statystyczny

6.1. Metryki pojedynczej transakcji i systemu

Wszystkie wyniki wyrażamy w **R** — wielokrotności zaryzykowanej kwoty ($1R$ = odległość wejście→stop × wielkość pozycji). Normalizacja w **R** uniezależnia statystyki od kapitału i pozwala porównywać strategie o różnych stopach.

Metryka	Definicja	Interpretacja / próg
Expectancy (E)	średni wynik transakcji w R : $E = p \cdot \tilde{W} - (1-p) \cdot \tilde{L}$	Musi być dodatnia po kosztach; sama w sobie nic nie mówi bez liczby okazji.
Profit factor (PF)	suma zysków / suma strat (wartości bezwzględne)	≥ 1.15 OOS. $PF > 2$ w backteście intraday = niemal na pewno błąd lub przeuczenie.
Win rate × payoff	p oraz $\tilde{W}/\tilde{L}$ raportowane osobno	Diagnostyka charakteru strategii; nie są celami samymi w sobie.
Sharpe (annualizowany)	$\sqrt{252} \cdot \text{mean}(\text{dziennie P\&L}) / \text{std}(\text{dziennie P\&L})$	≥ 0.8 OOS. Liczony na dziennych P&L, nie na transakcjach — porównywalność między strategiami o różnej częstotliwości.
Sortino	jak Sharpe, odchylenie tylko od strat	Raportowany pomocniczo; ważny dla strategii asymetrycznych.
Max drawdown (MDD)	największe obsunięcie krzywej kapitału (w R i w %)	Wraz z czasem trwania DD — najdłuższy okres pod wodą w dniach.
MAR / Calmar	zwrot roczny / MDD	Zdrowe systemy intraday: ≥ 0.5 OOS.
SQN	$\sqrt{N} \cdot \text{mean}(R) / \text{std}(R)$	Jakość systemu wg Tharpa; > 2 solidny, ale wrażliwy na N — tylko pomocniczo.
Koncentracja	udział 5 najlepszych dni w wyniku	$< 40\%$; usunięcie top-5 dni nie zmienia znaku wyniku (próg z 1.3).

6.2. Rozkłady zamiast średnich

Każdy raport hipotezy zawiera pełne rozkłady, nie tylko momenty: histogram wyników w **R**, wynik per rok kalendarzowy, per segment sesji, per reżim zmienności (tercyle ATR-percentyla), per dzień tygodnia oraz per „dzień zdarzeniowy vs zwykły”. Doświadczenie uczy, że **strategia agregatowo zyskowna jest prawie zawsze mozaiką**: silna w jednym plastrze, neutralna w większości, stratna w niektórych. Zrozumienie mozaiki to połowa drogi do ulepszenia reguły — i naturalne źródło kolejnych hipotez.

6.3. Sharpe: annualizacja i pułapki

$$SR_{\text{ann}} = \sqrt{252} \cdot (\text{mean}(r_d) - r_f/252) / \text{std}(r_d) \quad [r_d - \text{dziennie P\&L}; r_f \text{ pomijalne dla intraday}]$$

Trzy pułapki, które silnik ma obowiązek obchodzić: **(1)** autokorelacja dziennych wyników zawayża annualizowany SR — raportujemy też SR z poprawką Lo (wariancja skorygowana o autokowariancję); **(2)** strategię o rzadkich transakcjach mają dni zerowe — std liczone tylko po dniach aktywnych zawayżałoby SR, liczymy po wszystkich dniach; **(3)** SR nie widzi asymetrii ogonów — dlatego zawsze towarzyszy mu MDD i Sortino.

6.4. Minimalna próba: istotność to nie moc

Wersja 1.0 tego dokumentu wyprowadzała minimalną licznosc z błędu standardowego: dla $\sigma \approx 1.2R$ i expectancy $+0.12R$ wychodziło $N \approx (1.96 \cdot 1.2 / 0.12)^2 \approx \mathbf{384}$. Rachunek jest poprawny, ale odpowiada na węższe pytanie, niż się wydaje: to **próg istotności**, a nie moc testu. Przy $N = 384$ wykryjemy prawdziwą przewagę $0.12R$ tylko w około **połowie przypadków** — reszta to fałszywe negatywy. Odrzucalibyśmy działające strategie rzutem monety.

$$N = ((z_{\alpha/2} + z_{\beta}) \cdot \sigma_R / E)^2$$

Moc testu	z_{β}	N ($\sigma=1.2R$, $E=0.12R$)	Rola w projekcie
50%	0.00	384	rachunek z v1.0 — niewystarczający
80%	0.84	785	cel operacyjny
90%	1.28	1 051	komfort dla kandydata do certyfikacji

Stąd progi z 1.3: **400 transakcji to podłoga bezwzględna** (spójna z własnym wyprowadzeniem istotności), a **celem jest 800+**. Poniżej podłogi nie formułujemy żadnych wniosków, nawet jeśli pozostałe metryki wyglądają dobrze.

Dwa zastrzeżenia, które trzeba respektować w kodzie. Po pierwsze, $\sigma_R = 1.2R$ to *założenie*, nie pomiar — strategie z długim ogonem zysków mają σ rzędu $1.5-2R$, co podnosi wymagane N kilkukrotnie; dlatego σ estymujemy empirycznie dla każdej strategii, a wzór analityczny służy wyłącznie do *planowania* wielkości próby. Po drugie, wyniki transakcji **nie są niezależne** (klastrowanie zmienności, reżimy), więc efektywna licznosc jest niższa od nominalnej — kryterium decyzyjnym jest bootstrapowy przedział ufności (BCa) z rozdz. 7.2, a nie normalny błąd standardowy. Zbieżność do rozkładu normalnego przy skośności i kurtozie typowej dla R-multipli jest wolna i klasyczne przedziały niedokrywają.

Konsekwencja projektowa: hipotezy o rzadkich sygnałach (dawne H004, H008) mają z góry dłuższą ścieżkę walidacji i niższy priorytet — przy 50 obserwacjach rocznie osiągnięcie mocy 80% jest poza zasięgiem naszej historii i karta nie może zostać certyfikowana, cokolwiek pokaże backtest.

6.5. Deflated Sharpe Ratio — nasza polisa przeciw samooszukaniu

Jeśli przetestujemy N wariantów strategii na szumie, najlepszy z nich będzie miał „światny” Sharpe — czysto losowo. Oczekiwane maksimum SR z N niezależnych prób o zerowej prawdziwej przewadze rośnie jak $\sqrt{(2 \cdot \ln N)} \cdot \sigma_{SR}$. DSR (Bailey & López de Prado) odpowiada na pytanie: *czy najlepszy znaleziony SR przekracza to, co dałoby samo losowanie?*

$$SR_0 = \sigma_{SR} \cdot [(1-\gamma) \cdot \Phi^{-1}(1-1/N) + \gamma \cdot \Phi^{-1}(1-1/(N \cdot e))] \quad \gamma \approx 0.5772$$

$$DSR = \Phi((SR - SR_0) \cdot \sqrt{(T-1)} / \sqrt{(1 - \gamma_3 \cdot SR + ((\gamma_4-1)/4) \cdot SR^2)})$$

gdzie N — efektywna liczba prób, T — długość próby (dni), γ_3/γ_4 — skośność i kurtoza dziennych zwrotów, Φ — dystrybuenta normalna. **Interpretacja:** DSR to prawdopodobieństwo, że prawdziwy SR jest dodatni, po uczciwym rozliczeniu z liczby prób. Wymagamy **DSR ≥ 0.95** .

TRZY WARUNKI POPRAWNEJ IMPLEMENTACJI

1. **Częstotliwość dzienna, nie annualizowana.** SR, γ_3 i γ_4 we wzorze muszą być liczone na dziennych zwrotach. Wstawienie SR annualizowanego to najczęstszy błąd implementacji DSR i daje wyniki bez sensu. γ_4 to kurtoza surowa (dla rozkładu normalnego równa 3), spójnie z członem $((\gamma_4-1)/4)$.
2. **σ_{SR} to rozrzut SR-ów między próbami**, czyli $\sqrt{V[\{SR_n\}]}$ z zarejestrowanych wariantów — tak stanowi *False Strategy Theorem*. Uproszczenie $\sigma_{SR} = 1/\sqrt{T}$ jest szczególnym przypadkiem czystego szumu iid; dopuszczamy je wyłącznie jako jawnie oznaczony fallback, gdy prób jest zbyt mało, by oszacować wariancję. Projekt i tak loguje SR każdego wariantu, więc poprawna wersja nic nie kosztuje.
3. **N to liczba prób efektywnych**, nie surowa liczba komórek siatki — algorytm w A.3.

Tabela wykonalności — narzędzie planowania hipotez

Zanim uruchomimy hipotezę, musimy wiedzieć, czy jej budżet prób w ogóle pozwala na certyfikację. Poniższa tabela podaje DSR przy $T = 1500$ dni (~6 lat zszyciego OOS — realny sufit projektu przy danych od 2019):

SR annualizowany	$N_{eff} = 1$	$N_{eff} = 5$	$N_{eff} = 10$	$N_{eff} = 30$
0.8	0.974 ✓	0.776 ✗	0.647 ✗	0.452 ✗
1.0	0.993 ✓	0.894 ✗	0.806 ✗	0.643 ✗
1.2	0.998 ✓	0.958 ✓	0.912 ✗	0.803 ✗
1.5	1.000 ✓	0.993 ✓	0.981 ✓	0.943 ✗

Oraz — patrząc z drugiej strony — ile dni OOS potrzeba, żeby DSR osiągnęło 0.95 przy pojedynczej próbie:

SR annualizowany	Wymagane T	W latach OOS
0.8	1 070 dni	≈ 4.2 lat
1.0	690 dni	≈ 2.7 lat
1.2	480 dni	≈ 1.9 lat
1.5	310 dni	≈ 1.2 lat

CO Z TYCH TABEL WYNIKA — I DLACZEGO ISTNIEJE SYSTEM DWUSTOPNIOWY

Kombinacja progów z wersji 1.0 („Sharpe ≥ 0.8 przy DSR > 0.95 ”) była **nieprzechodnia**: nawet przy jednej jedynej próbie wymagałaby ponad czterech lat czystego OOS, a przy realistycznych pięciu-dziesięciu próbach na hipotezę jest poza zasięgiem niezależnie od długości historii. Limit 30 wariantów z v1.0 był w tym świetle samobójczy — przy $N_{eff} = 30$ nie przechodzi nawet strategia o Sharpe 1.5.

To nie jest wada konstrukcji dokumentu, tylko treść *False Strategy Theorem*: **nie istnieje próg Sharpe odporny na liczbę prób**. Odpowiedzią nie może więc być ani udawanie, że problemu nie ma, ani obniżenie poprzeczki. Odpowiedzią jest rozdzielenie dwóch pytań — „czy to wygląda na przewagę ekonomiczną?” (Tier 1) i „czy da się to statystycznie certyfikować?” (Tier 2) — oraz wskazanie jedynej uczciwej drogi z pierwszego do drugiego: **forward paper trading, który dokłada T bez zużywania prób**.

GLOBALNY LICZNIK PRÓB — REGUŁA BEZWZGLĘDNA

Każdy przebieg backtestu — każda kombinacja parametrów w każdej siatce każdej hipotezy — inkrementuje globalny licznik `n_trials` zapisywany w repo (`validation/trial_counter.json`). DSR każdego kandydata liczy się względem **całego** licznika projektu (z korektą na korelację między wariantami — warianty jednej hipotezy są silnie skorelowane, liczymy efektywną liczbę prób przez klastrowanie). Bez tej reguły „próbujemy aż się uda” byłoby matematycznie gwarantowanym samooszustwem: po 1000 prób na czystym szumie najlepszy wariant miałby $SR \approx 3 \cdot \sigma_{SR}$. Z tą regułą — im dłużej szukamy, tym wyższy próg musi przeskoczyć zwycięzca. To jest cena uczciwości i płacimy ją świadomie.

Przykład liczbowy. Po przetestowaniu efektywnie 200 niezależnych wariantów, przy $T = 500$ dni OOS: $\sigma_{SR} \approx 1/\sqrt{T} \approx 0.045$ (dzienny), $SR_0 \approx 0.045 \cdot 2.9 \approx 0.13$ dziennego $SR \approx 2.1$ annualizowanego — czyli *sam próg losowości* dwukrotnie przekracza nasz próg jakości. Dlatego kluczowe są dwie rzeczy naraz: poprawna korekta klastrowa (warianty jednej hipotezy są silnie zależne) i **żelazna dyscyplina małych siatek**.

LIMIT PRÓB: ≤ 10 WARIANTÓW NA HIPOTEZĘ

Wersja 1.0 dopuszczała 30 wariantów. Tabela wykonalności pokazuje, że przy $N_{eff} = 30$ nie przechodzi nawet strategia o Sharpe 1.5 — limit był w praktyce gwarancją porażki. **Nowy limit to 10 wariantów**, przy czym każdy musi być uzasadniony mechanizmem *przed* testem. To zmienia sposób pracy: nie przeszukujemy siatki, żeby zobaczyć, co wyjdzie — projektujemy garść wariantów, o których potrafimy powiedzieć, dlaczego akurat one.

Drugim źródłem oszczędności jest kategoria **benchmarków** (rozdz. 9): cztery karty katalogu uruchamiane są raz, z parametrami wprost z literatury, bez optymalizacji — i dlatego *nie zużywają licznika prób*. Służą jako punkt odniesienia w teście przyrostowym, a nie jako kandydaci.

6.6. Moc testu i projektowanie eksperymentu

Przed każdym backtestem karta hipotezy (aneks D) wymaga wypełnienia sekcji „projekt eksperymentu”: oczekiwana częstość sygnałów (z eksploracji rozkładów), wynikająca z niej liczba transakcji w oknie OOS, minimalny wykrywalny efekt (MDE) przy tej liczbie. Jeśli $MDE >$ realistyczna przewaga (np. strategia dawałaby 40 transakcji OOS, więc wykrywalne byłoby dopiero $E > 0.37R$ — nierealistyczne), hipoteza wraca do przeprojektowania *zanim* spali budżet prób. To eliminuje całą klasę „testów, które nie mogły się udać”.

Framework walidacji

7.1. Podział danych i walk-forward

Historia: 2019 ————— 2026-07
 |— EKSPLOACJA + IN-SAMPLE (60%) —|— OOS walk-forward (40%) —|

Walk-forward: [IS 12 mies.][OOS 3 mies.] → przesunięcie o 3 mies. → ...
 parametry zamrażane na IS, wykonanie na OOS,
 krzywa OOS = konkatencja WYŁĄCZNIE okien OOS

- **Ostatnie 6 miesięcy historii = sejf (lockbox).** Nie dotykamy ich w żadnej iteracji badawczej; służą wyłącznie do finalnej, jednorazowej weryfikacji kandydata przed decyzją GO na paper trading. Jedno spojrzenie na sejf = zużycie sejfu (odnotowane w rejestrze).
- Optymalizacja parametrów na IS: wyłącznie siatki zdefiniowane w karcie hipotezy (≤ 30 wariantów), bez doszukiwania.
- Wynik hipotezy = metryki krzywej OOS. Metryki IS raportujemy tylko diagnostycznie (rozjazd IS/OOS $> 50\%$ na PF = czerwona flaga przeuczenia).
- **DSR liczymy na pełnym zszytym szeregu OOS**, nie na pojedynczym oknie — maksymalizacja T jest jedyną dźwignią, którą mamy po stronie danych.

CPCV — dlaczego sam walk-forward nie wystarcza (nowe w v1.1)

Klasyczny walk-forward generuje **jedną ścieżkę OOS** — tę jedną, którą historia akurat ułożyła. Ocena strategii staje się przez to wrażliwa na przypadkową kolejność reżimów rynkowych: ta sama reguła wypadłaby inaczej, gdyby bessy 2022 przyszła przed hossą AI, a nie po niej. **Combinatorial Purged Cross-Validation** (López de Prado, *AFML* rozdz. 12) dzieli historię na N spójnych bloków i wybiera k bloków testowych, generując wiele historycznie spójnych ścieżek OOS zamiast jednej.

Cecha	Walk-forward (12m/3m)	CPCV (N=6, k=2 → 15 ścieżek)
Liczba ścieżek OOS	1, sekwencyjna	15 — otrzymujemy rozkład Sharpe'a, nie punkt
Wykorzystanie danych	Częściowe (rozgrzewka okien)	100% danych występuje w warunkach OOS
Wrażliwość na kolejność reżimów	Wysoka	Niska — testuje kombinacje różnych okresów
Estymacja przeuczenia	Porównanie IS vs OOS	Pozwala policzyć PBO

Rola każdego z nich: walk-forward zostaje jako symulacja realistycznego narastania kapitału (tak wyglądałby rachunek, gdybyśmy handlowali od 2020 roku); CPCV jest **obowiązkową bramką przed otwarciem lockboxa** i źródłem rozkładu wyników oraz metryki PBO. Moduł: `validation/cpcv.py`.

7.2. Monte Carlo — trzy testy

Test	Procedura	Kryterium
Permutacja kolejności	5 000 × losowa permutacja sekwencji transakcji OOS; rozkład MDD i najdłuższego DD.	Realny MDD < 95. percentyl rozkładu; planowanie kapitału bierze 95. percentyl, nie historyczny MDD.

Bootstrap wyniku	5 000 × próbkowanie ze zwracaniem, w dwoch wariantach : po transakcjach oraz blokowo po dniach (bloki o losowej długości ~1 dzień sesyjny). Przedziały BCa dla E i PF.	Dolna granica 95% CI dla $E > 0$ w wariancie blokowym . Bootstrap po transakcjach zakłada niezależność, której nie ma — przy klastrowaniu zmienności daje przedziały zbyt wąskie, czyli fałszywą pewność.
Test na danych bez struktury	Pełny pipeline hipotezy uruchomiony na ≥1000 seriach syntetycznych (bootstrap blokowy zwrotów M1 — zachowuje rozkład i klastry zmienności, niszczy strukturę czasową). Warunek krytyczny: na syntetykach wykonujemy dokładnie tyle samo prób optymalizacyjnych co na danych realnych.	Wynik na danych realnych > 95. percentyl wyników na syntetykach. Najmocniejszy pojedynczy test w arsenale: mierzy, ile „zysku” generuje sama procedura badawcza. (v1.0 zakładała 200 serii — za mało: minimalne osiągalne p wynosiło 0.005, a oszacowanie percentyla było szumne.)

Testy overfittingu procesu selekcji (nowe w v1.1)

Powyższe trzy testy mierzą własności *znalezionej* strategii. Żaden z nich nie odpowiada na pytanie, ile przewagi wygenerował sam *proces wybierania* najlepszego wariantu z puli. Dokładają to dwa narzędzia:

Test	Co mierzy	Bramka
PBO przez CSCV (Bailey, Borwein, López de Prado, Zhu)	Prawdopodobieństwo, że wariant najlepszy in-sample wypadnie <i>poniżej mediany</i> out-of-sample. Idealnie pasuje do naszej struktury partii wariantów.	PBO < 0.20
SPA Hansena (alternatywa: White’s Reality Check)	Bootstrap stacjonarny po szeregach zwrotów <i>wszystkich</i> wariantów naraz: czy najlepszy bije benchmark zerowy po uwzględnieniu data-snoopingu. SPA ma większą moc niż Reality Check dzięki studentyzacji i mniejszą wrażliwość na słabe warianty w puli.	odrzućenie H_0 przy $\alpha = 0.05$ gotowa implementacja: <code>arch.bootstrap.SPA</code>

Opcjonalnie, gdy pula wariantów jest większa: procedura zstępująca Romano-Wolfa do wskazania, *które konkretnie* warianty przeżywają korektę na wielokrotne testowanie, a nie tylko czy przeżywa najlepszy.

7.3. Purging i embargo — dla wszystkich strategii, nie tylko swing

Między oknem treningowym a testowym usuwamy **purge** — bufor równy maksymalnemu horyzontowi pozycji, który eliminuje przeciek przez transakcje rozpięte na granicy okien — oraz **embargo** chroniące przed przeciekami przez autokorelację zmienności.

Typ strategii	Purge	Embargo	Uzasadnienie
Swing / overnight	maks. horyzont pozycji (dni)	5 dni	Bez tego walk-forward na strategiach wielodniowych systematycznie zawyża wyniki.
Intraday	do końca dnia sesyjnego	≥ 60 minut	Wersja 1.0 zwalniała intraday z tego wymogu — błędnie. Zmienność wewnątrzdziennej jest silnie autokorelowana, więc bar tuż po granicy okna niesie informację o barze tuż przed nią.

Purging i embargo obowiązują zarówno w walk-forward, jak i w CPCV — w tym drugim są warunkiem poprawności całej konstrukcji.

7.4. Odporność parametryczna: plateau, nie szczyt

Dla kandydata liczymy pełną siatkę $\pm 20\%$ wokół wybranych parametrów (co najmniej 2 parametry $\times$ 5 wartości). Kryteria: **(a)** wszystkie komórki siatki dodatnie po kosztach; **(b)** odchylenie standardowe PF w siatce $< 25\%$ średniej; **(c)** wybrany punkt nie jest maksimum siatki (jeśli jest — przesuwamy się do środka plateau). Heatmapa siatki obowiązkowo w raporcie. Uzasadnienie: prawdziwy efekt strukturalny jest rozmyty w przestrzeni parametrów; szpilka („działa tylko dla okresu 17, dla 15 i 19 traci”) to sygnatura dopasowania do szumu.

7.5. Testy transferu

Test	Oczekiwanie i interpretacja
MNQ $\rightarrow$ NQ	Wynik musi się przenosić niemal 1:1 (ten sam indeks). Brak transferu = błąd danych/silnika, nie cecha rynku.
MNQ $\rightarrow$ ES	Trzy dopuszczalne wyniki: przenosi się (efekt ogólnorynkowy — dobrze), słabnie ale znak zachowany (efekt wzmocniony specyfiką Nasdaq — dobrze), znika całkowicie. Zniknięcie wymaga wyjaśnienia mechanizmem z rozdz. 2.2 — jeśli mechanizm jest specyficzny dla NQ (np. koncentracja big-tech, H009), OK; jeśli mechanizm powinien działać wszędzie, a działa tylko na MNQ — czerwona flaga.
Podokresy reżimowe	Wynik osobno dla: 2019 (niska zmienność), 2020 (COVID), 2022 (bessa), 2023–25 (hossa AI). Nie wymagamy zysku w każdym; wymagamy zrozumienia, gdzie strategia traci i czy filtr reżimowy to wychwytuje.

7.6. Bramka walidacyjna — dwie listy kontrolne

Bramka Tier 1 — status PROMISING (uprawnia do forward paper tradingu):

- | | |
|--|--|
| ☐ ≥ 400 transakcji 00S (podłoga; cel 800+, moc 80%) | ☐ Sharpe 00S ≥ 0.8 |
| ☐ PF 00S ≥ 1.15 przy pełnych kosztach | ☐ top-5 dni $< 40\%$ wyniku |
| ☐ zysk w ≥ 3 z 4 lat | ☐ IS/00S rozjazd PF $< 50\%$ |
| ☐ plateau $\pm 20\%$ w całości dodatnie | ☐ MC-bootstrap blokowy: CI-BCa(E) > 0 |
| ☐ MC-permutacja: MDD $< p95$ | ☐ MC-syntetyki (≥ 1000 serii, równy budżet prób): wynik $> p95$ |
| ☐ MC-syntetyki (≥ 1000 serii, równy budżet prób): wynik $> p95$ | ☐ SPA Hansena: H0 odrzucone |
| ☐ PBO < 0.20 (CSCV) | ☐ purge + embargo zastosowane |
| ☐ CPCV: rozkład Sharpe'a raportowany | ☐ transfer ES wyjaśniony mechanizmem |
| ☐ transfer NQ $\approx 1:1$ | ☐ pasmo wrażliwości barów spornych raportowane |
| ☐ stress kosztów $\times 2$: nadal dodatnia | ☐ ablacje: każdy warunek coś wnosi |
| ☐ test przyrostowy ponad benchmark dodatni | ☐ wpis REGISTRY zaktualizowany |
| ☐ raport kompletny w reports/ | |


Bramka Tier 2 — status CERTIFIED (jedyna droga do rozmowy o realnym kapitale):

- ☐ wszystkie pozycje Tier 1 spełnione
- ☐ DSR ≥ 0.95 na pełnym zszytym 00S (backtest + zgromadzony paper),
liczone z sigma_SR wg False Strategy Theorem i N_eff wg algorytmu z A.3
- ☐ lockbox otwarty JEDEN raz i wynik zgodny z resztą 00S
- ☐ kryteria paper tradingu z 11.4 spełnione

Kolejność jest nieprzypadkowa: lockbox otwieramy dopiero po przejściu wszystkich testów, które da się wykonać bez niego. Jedno spojrzenie do sejfu = zużycie sejfu, odnotowane w rejestrze.

Fabryka hipotez — proces

8.1. Cykl życia hipotezy



Każde przejście stanu = commit z aktualizacją `REGISTRY.md`. Stan `REJECTED` jest trwały — hipoteza może wrócić wyłącznie jako *nowa* karta z nowym ID i jawnym odwołaniem do poprzedniczki („H017, wariant H003 z wnioskiem W-12”).

8.2. Etap eksploracji — badanie bez backtestu

Zanim powstanie jakakolwiek reguła handlowa, hipoteza musi wykazać istnienie efektu w czystych rozkładach warunkowych. Przykład dla H001: bierzemy wszystkie dni, dzielimy na kwintyle zakresu nocnego, i dla każdego kwintyla liczymy rozkład: zasięgu ruchu od otwarcia RTH, częstości domknięcia dnia w kierunku wybicia z pierwszych 15 minut, stosunku zasięgu kontynuacji do cofnięcia. Jeżeli mediany i ogony tych rozkładów nie różnią się między kwintylami w sposób istotny (test Manna-Whitneya, $p < 0.01$ po poprawce Bonferroniego na liczbę porównań w karcie) — **nie ma czego handlować** i hipoteza umiera za darmo, bez zużywania budżetu backtestów. Eksploracja pracuje wyłącznie na oknie IS (60%); okno OOS pozostaje nietknięte do walk-forward.

8.3. REGISTRY.md — pamięć instytucjonalna

ID	Hipoteza (1 zdanie)	Klasa	Status	Werdykt / wniosek
H001	ON-range			

Rejestr pełni trzy funkcje: **(1)** zabezpiecza ciągłość między sesjami agenta – każda sesja zaczyna od przeczytania

8.4. Test oryginalności – czterokrokowy (przepisany w v1.1)

DLACZEGO POPRZEDNIA REGUŁA BYŁA BŁĘDNA

Wersja 1.0 stanowiła, że reguła łącząca *dwie niezależne klasy mechanizmów* spełnia wymóg oryginalności. A

Kontrprzykład rozstrzyga sprawę: opening range breakout z filtrem zmienności łączy dwie klasy (rytm sesji

Każda karta hipotezy musi przejść cztery kroki. Pierwsze dwa wykonuje się **przy pisaniu karty**, przed jakimkolwiek

Krok	Wymóg	Co konkretnie
1	Zidentyfikuj najbliższy publiczny benchmark	Nazwij z nazwiska i roku najbliższy opublikowany benchmark
2	Nazwij różnicę w <i>mechanizmie</i>	Jednym zdaniem: co w przyczynie zjawiska – różnica
3	Test przyrostowy OOS	Czy karta dodaje wartość <i>ponad</i> benchmark po
4	Ablacje	Usuń po kolei każdy warunek deklarowany jako

Reguły uzupełniające (pozostają z v1.0)

- Zakaz kopiowania setupów.** Znane efekty (np. dryf overnight – fakt naukowy) są dozwolonym punktem wyjścia
- Własne definicje operacyjne.** Każdy reżim i filtr definiujemy od zera na własnych danych. Konieczne, ale
- Test crowdingu.** Karta zawiera ocenę zatłoczenia: jak popularne są zbliżone podejścia i co stałoby się z
- Wywodliwość.** Musi istnieć ścieżka: mechanizm (2.2) → efekt w rozkładach (8.2) → reguła. Reguła bez tej ś
- Ostrożność z „zanikiem po publikacji”.** Przeciętne słabnięcie przewidywalności po publikacji (McLean–Pont

8.5. Budżet i rytm iteracji

- Partia = 3–5 kart naraz (wspólna eksploracja tła: te same rozkłady bazowe służą wielu kartom).
- Jedna iteracja karty (eksploracja → werdykt wstępny) ≈ 1–2 dni robocze agenta.
- Limit siatki: ≤ 10 wariantów/kartę; limit partii: ≤ 40 wariantów – kontrola tempa wzrostu `n_trials`. Be

- Po każdej partii: przegląd wniosków W-xx i projektowanie następnej partii z *ich uwzględnieniem*. To jest

ROZDZIAŁ 9

Katalog hipotez: benchmarki, przeformułowania, kandydaci

9.1. Jak audyt przebudował ten rozdział

Wersja 1.0 zawierała dwanaście kart przedstawionych jako równorzędni kandydaci na oryginalną strategię. Aud

Odpowiedzią nie jest usunięcie tych kart, lecz **przypisanie im właściwych ról**. Katalog dzieli się teraz na t

Kategoria	Karty	Rola i koszt dla licznika prób
Benchmarki	B01–B04 (dawne H006, H007, H008, H012)	Uruchamiane raz , z parametrami wprost
Przeformułowane	H001–H004	Pytanie zmienione z „czy znany efekt c
Kandydaci	H005, H010, H011, H013, H014, H016 (H015 warunkowa)	Główny front oryginalnych badań. Najni

Każda karta zawiera odtąd trzy nowe, obowiązkowe pola wynikające z testu z rozdz. 8.4: **najbliższy publi**

9.2. Stan wiedzy: co jest znane i czy nadal działa

Podstawa rekategoryzacji – dla każdej rodziny efektów: od kiedy jest znana i jaki jest udokumentowany statu

Rodzina efektów	Znana od	Sta
Dryf overnight na indeksach US	2008 (Cooper–Cliff–Gulen)	Udo
Opening range / Initial Balance	lata 80. (Steidlmayer), ok. 1990 (Crabel)	Mot
Poziomy referencyjne (PDH/PDL, wsparcia i opory)	2000, 2003 (Osler)	Mec
Efekty dnia tygodnia, weekend effect	1973, 1980 (Cross, French)	W d
Wzorzec U-kształtny sesji (lunch)	koniec lat 80.	Fak
OPEX, rebalancing indeksów, mechanika zamknięcia	lata 80. / 2013 / 2018	Efe

9.3. Rejestr benchmarków (B01–B04)

Te cztery karty **nie są kandydatami na oryginalną strategię**. Uruchamiamy je raz, z parametrami z literatury,

ID	Karta	Publiczny odpowiednik
----	-------	-----------------------

B01	Gap otwarcia i jego domknięcie (dawne H006)	Gap-fill – jeden z najstarszych i najszerzej znanych se
B02	Cykl kontrakcja–ekspansja zakresu (dawne H007)	Rodzina NR7 i pochodne, Crabel, ok. 1990 – wprost
B03	Asymetria piątek→poniedziałek (dawne H008)	Weekend effect, Cross 1973 / French 1980
B04	Mechanika zamknięcia / proxy MOC (dawne H012)	Momentum wewnątrzdzienne, Gao i in., <i>Journal of Financi</i>

9.4. Karty przeformułowane (H001–H004)

Cztery karty o mechanizmach wartych ratowania – pod warunkiem przejścia kroków 1 i 2 testu oryginalności. P

H001 – Kompresja nocna: przyczyna, nie sam fakt

K1 × K3 · INTRADAY

Przeformułowanie: nie „czy wybiecie po wąskiej nocy działa”, lecz czy kompresja nocna o różnym pochodzeniu

Publiczny benchmark	ORB / Initial Balance na dniu kontrakcji (Steidlmayer, Crabel) –
Wymagana różnica mechanizmu	Benchmark traktuje wąski zakres jako jednorodny sygnał. My rozróż
Siatka (≤10)	próg kompresji: p20 / p30; klasyfikator pochodzenia: wolumen noc
Plan ablacji	Usunąć klasyfikator pochodzenia → jeśli wynik bez zmian, karta j
Falsyfikacja	Rozkłady sesji RTH nierozróżnialne między typami kompresji.

H002 – Powrót do VWAP: kto stoi po drugiej stronie

K1 × K5 × K3 · INTRADAY

Przeformułowanie: nie „czy cena wraca do VWAP w lunchu”, lecz czy odchylenie powstałe przy niskim wolumen

Publiczny benchmark	„Lunch VWAP fade” – bardzo popularny setup detaliczny; ciekawe,
Wymagana różnica mechanizmu	Benchmark handluje samo odchylenie. My warunkujemy je strukturą
Siatka (≤10)	próg wejścia: 1.5 / 2.0 / 2.5 σ_{vwap} ; próg wolumenowy: mediana /
Plan ablacji	Usunąć warunek wolumenowy → jeśli wynik bez zmian, karta jest zw
Falsyfikacja	Prawdopodobieństwo powrotu niezależne od struktury wolumenu odch

H003 – Reakcja na publikację: co odróżnia odwrócenie od kontynuacjiK4 · EVEN

Przeformułowanie: nie „czy fade'ować pierwszy ruch po danych”, lecz które cechy samej reakcji przewidują

Publiczny benchmark	Literatura reakcji na ogłoszenia makro (dryf vs odwrócenie) + ob
Wymagana różnica mechanizmu	Benchmark zakłada stałą tendencję. My twierdzimy, że rozstrzyga
Siatka (≤ 10)	okno wejścia: 10 / 15 / 20 min po publikacji; warunek struktural
Plan ablacji	Usunąć warunek strukturalny → zostaje czysty fade czasowy (bench
Falsyfikacja	Kontynuacja niezależna od położenia impulsu względem poziomów. U

H004 – Dryf nocny: czy w ogóle jeszcze istniejeK2 × K3 · SWING · WARUNKOWA

Przeformułowanie wymuszone: zanim zapytamy „w jakich reżimach dryf jest silniejszy”, musimy sprawdzić, cz

TEST WSTĘPNY – OBOWIĄZKOWY PRZED JAKĄKOLWIEK PRACĄ NAD TĄ KARTĄ

Zewnętrzne badania wskazują na wygaśnięcie dryfu overnight na indeksach US po roku 2020. Nie przyjmuje

- Dryf obecny w ostatnich latach → karta wchodzi do badań z pytaniem o warunkowość reżimową.
- Dryf wygasł → karta schodzi do benchmarków, a sam wynik trafia do rejestru jako wniosek przekrojowy

Publiczny benchmark	Dryf overnight (Cooper–Cliff–Gulen 2008 i literatura następcza)
Wymagana różnica mechanizmu	Warunkowanie strukturą zamknięcia RTH i kalendarzem zdarzeń. Ryz
Siatka (≤ 10)	pozycja close w zakresie dnia: górny tercyl / kwartył; kierunek

9.5. Kandydaci – główny front badań

H005 – Mikrostruktura kolejnych testów poziomu

K5 · INTRADAY · PRIORYTET

Hipoteza: pierwszy w sesji test poprzedniego dziennego ekstremum zachowuje się statystycznie inaczej niż

Mechanizm	Na poziomach referencyjnych skoncentrowane są zlecenia pasywne i sto
Publiczny benchmark	Klasyczne wsparcia i opory (Osler 2000/2003) – mechanizm klastrowani
Różnica mechanizmu	Benchmark opisuje <i>istnienie</i> reakcji na poziomie. My badamy wyczerpyw
Siatka (≤ 10)	definicja testu: zbliżenie $\leq 2 / 4 / 8$ ticków; wariant: fade pierwsz
Plan ablacji	Zastąpić numer testu wartością stałą → jeśli wynik bez zmian, karta
Falsyfikacja / crowding	Rozkład reakcji niezależny od numeru testu. Ryzyko zatłoczenia średn

H010 – Zmienność zrealizowana wobec oczekiwanej $K3 \times K1$ · INTRADAY · WARSTWA REŻIMU

Hipoteza: znaczenie ma nie bezwzględny zakres nocny, lecz jego relacja do reżimu – noce „cichsze niż powi

Mechanizm	Zrealizowana cisza przy wysokich oczekiwaniach zmienności to odroczo
Publiczny benchmark	Literatura reżimów zmienności; sama interakcja zakresu nocnego z reż
Różnica mechanizmu	Normalizacja zakresu nocnego <i>własnym</i> proxy oczekiwań zbudowanym z sa
Siatka (≤ 10)	proxy reżimu $ATR(5d)/ATR(60d)$: tercyle; handlowane narożniki mapy: 2
Rola dodatkowa	Warstwa reżimowa dla innych kart. Nawet jeśli nie utworzy samodzieln
Falsyfikacja / crowding	Mapa płaska – typ dnia niezależny od narożnika. Ryzyko zatłoczenia n

H011 – Sekwencja sesji Azja→Europa jako predyktor $K1$ · INTRADAY · NAJWYŻSZY PRIORYTET

Hipoteza: konfiguracja dwóch segmentów nocy – zgodność lub spór między kierunkiem Azji a kierunkiem Europ

Mechanizm	Azja i Europa to różne populacje kapitału. Europa „głosująca” przeci
Publiczny benchmark	Nie zidentyfikowano rozpoznawalnego opublikowanego setupu. Analiza s
Różnica mechanizmu	Sam przedmiot badania jest inny: nie poziom ani zakres, lecz relacja
Siatka (≤ 10)	granice segmentów: bazowe / $\pm 1h$; typy sekwencji handlowane: 1 lub 2
Plan ablacji	Zastąpić sekwencję łącznym zakresem nocnym → mierzy dokładnie przyro
Falsyfikacja / crowding	Rozkłady RTH nierozróżnialne między typami sekwencji po poprawce na

H013 – Rezydualny repricing po wynikach megacapów

K6 × K4 · EVENT-DRIVEN · PRIORYT

Hipoteza: po publikacji wyników spółki o dużej wadze w indeksie kontrakt bywa nie- lub przereagowany wzgl

$$\text{impuls implikowany NDX} \approx \sum w_i \cdot r_i^{\text{(after-hours)}}$$

$$\text{sygnał rezydualny} = r_{NQ} - \sum w_i \cdot r_i - \beta_{ES} \cdot r_{ES} - \beta_{SOX} \cdot r_{SOX}$$

Mechanizm	Wyniki spółki o wadze kilku procent indeksu to repricing całego koszu
Publiczny benchmark	Dryf po publikacji wyników (PEAD) – anomalia znana od dekad, ale dot
Różnica mechanizmu	Benchmark handluje <i>zachowanie kontraktu</i> dzień po. My modelujemy tran
Dane	Wymaga warstwy K6 z rozdz. 4.7: wagi NDX, ruchy after-hours 8 megaca
Siatka (≤10)	próg rezyduum: p70 / p80 / p90 rozkładu; okno estymacji bety: 60 / 1
Plan ablacji	(a) usunąć kontrolę β_{ES} – ile przewagi to sam kierunek rynku; (b) za
Falsyfikacja / crowding	Rezyduum nie ma mocy predykcyjnej ponad surowy gap. Ryzyko zatłocze

H014 – Dywergencja NQ–ES wokół szoków stóp

K6 × K4 · INTRADAY/SWING

Hipoteza: Nasdaq-100 jest indeksem o wysokiej duracji (spółki wzrostowe), więc reaguje na szoki stopowe s

Mechanizm	Wrażliwość na stopy różnicuje oba indeksy fundamentalnie, ale przepływ e
Publiczny benchmark	Handel spreadem NQ–ES jest znany; wersja warunkowana zdarzeniami stopowy
Różnica mechanizmu	Nie handlujemy spreadu jako powrotu do średniej, lecz rozbieżność między
Dane / siatka	ES z warstwy K6 (4.7). Siatka: okno reakcji 15 / 30 / 60 min; próg dywer
Falsyfikacja	Spread NQ–ES w oknach stopowych nierozróżnialny od zachowania w oknach k

H016 – Reżim dyspersji składników indeksu

K6 × K3 · WARSTWA REŻIMOWA

Hipoteza: rozpad korelacji między megacapami (wysoka dyspersja) zmienia charakter dnia indeksu – z trendu

Mechanizm	Gdy składniki poruszają się zgodnie, indeks trenduje; gdy się rozjeżdżają
Publiczny benchmark	Handel dyspersją jest znany w świecie opcyjnym (korelacja implikowana vs
Różnica mechanizmu	Nie handlujemy dyspersji jako aktywa; używamy jej jako zmiennej stanu op
Sposób oceny	Karta oceniana głównie przyrostem, jaki wnosi do innych kart (H005, H011
Dane / siatka	Składniki z warstwy K6. Siatka: okno dyspersji 5 / 10 / 20 dni; próg reż

H015 – Price discovery NQ–MNQ

K6 · ZAREJESTROWANA, NIEBADALNA

Hipoteza: odkrywanie ceny zachodzi na kontrakcie pełnym (NQ), a mikro (MNQ) podąża z opóźnieniem – mierza

KARTA ŚWIADOMIE WSTRZYMANA

Zjawiska lead-lag między kontraktami rozgrywają się w skali milisekund. **Na barach minutowych każdy wyn**

Zapisujemy ją mimo to, bo jawne odnotowanie „wiemy o tym mechanizmie i wiemy, dlaczego go nie badamy”

9.6. Kolejność badań i logika portfela

Partia	Skład	Uzasadnienie kolejności
Partia 0	Test wstępny dryfu nocnego + uruchomienie benchmarków B01–B04	Tanie, szybkie, rozstr
Partia 1	H011, H005, H010	Najniższe pokrycie z 1
Partia 2	H013, H014, H016	Klasa K6 – wymaga gotc
Partia 3	H001, H002, H003 (przeformułowane)	Najpierw muszą przejść

LOGIKA PORTFELA KATALOGU

Katalog pokrywa wszystkie sześć klas mechanizmów, trzy horyzonty i różne segmenty doby – bo **szukamy nie**

Zarządzanie ryzykiem

10.1. Zasada nadrzędna

Wielkość pozycji i limity strat mają większy wpływ na przetrwanie rachunku niż jakość sygnału. Strategia z

10.2. Sizing pozycji

$$\text{kontrakty} = \text{floor}(\text{kapitał} \times f / (\text{stop_pkt} \times 2 \text{ USD})), \quad f = 0.25\text{--}0.5\%$$

Kapitał	f = 0.25%	Stop 20 pkt (40 USD/kontrakt)	Stop 40 pkt (80 USD/kontrakt)
10 000 USD	25 USD	0 kontraktów – brak handlu	0 – brak handlu
16 000 USD	40 USD	1 kontrakt	0 – brak handlu
32 000 USD	80 USD	2 kontrakty	1 kontrakt

Tabela pokazuje twardą prawdę mikro kontraktów: przy $f = 0.25\%$ sensowny handel MNQ ze stopami 20–40 pkt zac

10.3. Hierarchia limitów

Limit	Wartość	Działanie po przekr
Transakcja	$1R = f \times \text{kapitał}$	Stop zawsze w rynku
Dzień	$-2R$	Koniec handlu do kc
Tydzień	$-4R$	Koniec handlu do po
Kill-switch strategii	$DD > 1.5 \times MDD$ z walidacji (95. percentyl MC)	Strategia wyłączona
Kill-switch projektu (live)	$DD \text{ rachunku} > 10\%$	Wszystkie strategie

10.4. Zakazy bezwzględne (wbudowane w kod)

- **Zero uśredniania w stratę.** Dokładanie do stratnej pozycji jest technicznie zablokowane w silniku i pętli
- **Zero handlu bez stopa.** Zlecenie wejścia bez towarzyszącego stopa jest odrzucane przez warstwę ryzyka.
- **Zero „odrabiania”.** Limit dzienny nie zna pojęcia „jeszcze jedna okazja”. Po $-2R$ system nie przyjmuje syg

- **Zero ręcznych interwencji w automat.** W fazie paper: każda ingerencja ręczna w pozycje automatu unieważnia
- **Zero zwiększania rozmiaru po serii zysków.** Rekalkulacja f następuje w stałym rytmie (miesięcznie), nie p

10.5. Portfel strategii (stan docelowy)

Jeżeli walidację przejdzie więcej niż jedna strategia, portfelem rządzą trzy zasady: **(1) budżet ryzyka** – su

ROZDZIAŁ 11

Paper trading i architektura live

11.1. Broker: Interactive Brokers – uzasadnienie i ograniczenia

Kryterium	Ocena IBKR
Konto paper	Pełnoprawne, darmowe, lustrzane API z kontem realnym – ta sama ś
API	Dojrzałe (TWS API / Gateway), biblioteka <code>ib_async</code> ; zlecenia bra
Futures CME micro	Pełny dostęp, niskie prowizje. Dane real-time: ~10 USD/mies. (US
Ograniczenia symulatora paper (oficjalne, nie anegdotyczne)	Wypełnienia wyłącznie z wierzchu księgi ; zlecenia stop są zawsze
Kapitał konta paper	Domyślnie 1 000 000 USD – wartość niereprezentatywna. Konto musi
Alternatywy odłożone	Tradovate i NinjaTrader (słabsze API do automatyzacji w Pythonie


PRZEBUDOWA ROLI PAPER TRADINGU (V1.1)

Skoro stopy są w symulatorze zawsze syntetyczne, a wypełnienia pochodzą wyłącznie z wierzchu księgi, to

1. **Walidacja automatu:** czy ścieżka sygnał → zlecenie → stan → odtworzenie po restarcie działa bez błędów
2. **Generator niezależnych danych OOS:** każdy tydzień handlu papierowego dokładnie T do szeregu, na którym l

Przewagę wykonania weryfikuje dopiero micro-live na jednym kontrakcie MNQ, po spełnieniu kryteriów z 11.

11.2. Architektura procesu live



- **Jeden proces, jedna strategia, jeden kontrakt** na start – złożoność dokładamy dopiero po stabilnym miesiącu
- **Godziny pracy procesu** zgodne z oknem strategii; poza oknem proces świadomie nie działa (mniejsza powierzchnia)
- **Restart-safety:** stan (pozycje, zlecenia) odtwarzany z API brokera przy starcie, nie z lokalnego pliku –
- **Idempotentny menedżer zleceń.** Zlecenia bracket, częściowe wypełnienia i wyścigi między potwierdzeniami i
- **Agregacja barów:** IBKR dostarcza bary **5-sekundowe**, więc bar minutowy powstaje po naszej stronie. To źródło
- **Ryzyka biblioteki:** `ib_async` jest społecznościowym forkiem projektu zamrożonego po śmierci autora, utrzym
- **Rutyny agenta:** Routine przed otwarciem RTH (sanity check: dane świeże? zdarzenia dziś? proces żyje?) i p

11.3. Tracking error – miara prawdy

Cotygodniowo, dla okresu paper, liczymy pięć osobnych serii. Kluczowe jest ich **rozdzielenie** – wersja 1.0 mi

Metryka

- (a) **Zgodność sygnałów** – czy backtest na danych z tego tygodnia wygenerowałby te same wejścia c
- (b) **Δ wypełnienia:** cena paper – cena modelowa, **osobno dla wejść, stopów i celów** (średnia i 95.
- (c) **Poślizg na stopach** zrealizowany vs modelowy, w rozbiciu na segmenty (RTH / otwarcie / zdar
- (d) **Zgodność barów:** bar minutowy złożony z 5-sekundowych danych IBKR vs bar Databento z dnia r
- (e) **Incydenty operacyjne:** rozłączenia, przymusowe zamknięcia, duplikaty zleceń, ręczne ingerenc

Dodatkowo, oddzielnie: **koszt rzeczywisty przekraczający 150% modelowego przez dwa tygodnie** wymusza rewizję

11.4. Kryteria przejścia paper → rozmowa o live

- [] ≥ 100 transakcji paper
- [] ≥ 8 tygodni kalendarzowych
- [] P&L paper (z narzutem poślizgu) w przedziale ufności z walidacji (bootstrap BCa)
- [] zgodność sygnałów $\geq 95\%$
- [] zero incydentów ręcznej ingerencji
- [] p95 poślizgu stopa $\leq$ model + 1 tick przez ≥ 4 tygodnie
- [] zgodność barów IBKR vs Databento bez systematycznego rozjazdu
- [] DD paper $< 1.0 \times \text{MDD}_{95}$ z walidacji
- [] status CERTIFIED: DSR ≥ 0.95 na szeregu łączonym (backtest OOS + paper)
- [] raport końcowy + rekomendacja agenta $\rightarrow$ DECYZJA WYŁĄCZNIE USERA

ILE PAPER TRADINGU POTRZEBA DO AWANSU NA TIER 2

Skoro paper dokłada niezależne dane OOS, można policzyć drogę awansu. Dla strategii o Sharpe rocznym ~ 0.5 .

To jest realna cena umiarkowanej przewagi i trzeba ją przyjąć bez złudzeń: *im słabsza strategia, tym dłużej*

ROZDZIAŁ 12

Harmonogram: tygodnie 1–12

Tydzień	Praca
1	Etap 0: struktura repo, pyproject, CI (pytest), draft PR-dziennik. Rdzeń silnika: load
2	Dokończenie silnika: features, metrics, walkforward, montecarlo, dsr, robustness. + mc
3	Etap 1: pobranie MNQ+NQ M1 2019→dziś, pipeline raw→clean, kontrakt ciągły, kalendarz z
4	Walidacja silnika na danych realnych (testy 5.6: zerowa przewaga, znany efekt, symetri
5	Partia 0: test wstępny dryfu nocnego (weryfikacja zaniku na własnych danych) + uruchom
6–7	Partia 1: H011, H005, H010 – rozkłady bazowe sesji (współdzielone), eksploracja per ka
8	Backtesty IS przeżywających kart; walk-forward + CPCV najlepszej; budowa warstwy dany
9–10	Partia 2: H013, H014, H016 (klasa K6, wymaga gotowej warstwy danych). MC + PBO + SPA +
11–12	Jeśli jest kandydat: bramka Tier 1 (7.6) $\rightarrow$ status PROMISING $\rightarrow$ start forward paper trac

REALIZM HORYZONTU – POPRAWKA WYNIKAJĄCA Z V1.1

Wersja 1.0 sugerowała, że dwanaście tygodni może wystarczyć do znalezienia zweryfikowanej strategii. Po

Ścieżka krytyczna: klucz Databento (tydzień 2→3) – jedyna zewnętrzna blokada pierwszych 4 tygodni. **Praca ró**

ROZDZIAŁ 13

Rejestr ryzyk projektu

Ryzyko	P.	Skutek	Mitygacja
Wadliwe dane (luki, złe rolowanie, błędne strefy)	Śr.	Krytyczny	Sanity-report p
Przeuczenie mimo aparatu	Śr.	Krytyczny	Cała bateria: l
Efekt istniał, ale zanikł (regime change / crowding)	Śr.	Wysoki	Analiza podokre
Koszty realne wyższe niż modelowe	Śr.	Wysoki	Konserwatywny m
Rozjazd paper vs live fills	Wys.	Średni	Narzut poślizgu
Przerwy ciągłości agenta (kontener efemeryczny, limity sesji)	Wys.	Średni	Wszystko w repc
Halucynacja/błąd agenta w kodzie badawczym	Śr.	Wysoki	Testy jednostkc
Utrata dyscypliny procesu pod presją „braku wyników”	Śr.	Krytyczny	Progi zamrożone
Zdarzenie ekstremalne w fazie paper/live (flash crash, halt)	Nis.	Wysoki	Watchdog + flat
Koszt danych/infrastruktury przekracza plan	Nis.	Niski	Budżet fazy bac

13.1. Ryzyka techniczne stacku (dodane w v1.1)

Poniższe ryzyka wyszły z zewnętrznej weryfikacji stacku danych i brokera. Są bardziej przyziemne niż powyżs

Ryzyko
Semantyka „brak bara = brak transakcji” wzięta za lukę w danych
Użycie serii continuous dostawcy bez własnego back-adjustu
Rozjazd barów dostawcy vs agregaty z transakcji (poprawki transakcji, znacznik zamknięcia bara)
Stopy zawsze symulowane w paper → niedoszacowanie ryzyka
Fork <code>ib_async</code> , rozłączenia bramki, niezgodność wersji Pythona
Throttling zapytań przy odtwarzaniu stanu po restarcie
Błędy stref czasowych (CT / ET / UTC) przy przerwie serwisowej i filtrach RTH
Zmiany opłat giełdowych i depozytów
Zmiana normalizacji danych po stronie dostawcy
Pojedyncze źródło danych bez kontroli krzyżowej
Konto paper z kapitałem 1 mln USD → nierealistyczny sizing
Bar minutowy składany z danych 5-sekundowych ≠ bar Databento
Wyścigi i duplikaty przy zleceniach bracket i częściowych wypełnieniach
Przekwalifikowanie z użytkownika niekomercyjnego na profesjonalnego

ROZDZIAŁ 14

Zarządzanie projektem i ciągłość między sesjami

14.1. Git workflow

- **Branch roboczy:** `claudio/financial-market-strategy-8mblyl` – całość pracy projektu; commity małe, opis
- **Draft PR = dziennik projektu.** Opis PR utrzymywany jako żywy status: co zrobione, co w toku, jakie decyzje
- **Tagi kamieni milowych:** `m1-engine-proven` , `m2-data-clean` , `m3-first-validation` ... – punkty, do których
- **Dane w repo:** `data/clean/*.parquet` commitowane (dziesiątki MB – akceptowalne); `data/raw/` w gitignore

14.2. Protokół wznowienia sesji agenta

1. `git pull` → przeczytaj `README.md` (stan projektu w 10 liniach)
 2. przeczytaj `hypotheses/REGISTRY.md` (co żyje, co umarło, jakie wnioski)
 3. przeczytaj opis draft PR (ostatni status, otwarte decyzje)
 4. sprawdź `validation/trial_counter.json` (budżet prób)
 5. kontynuuj od pierwszego niedomkniętego punktu bieżącej partii
- Zasada: KAŻDY stan wart utrzymania jest w repo. Sesja, która czegoś nie scommitowała, tego czegoś nie zrobiła.

14.3. Punkty decyzyjne usera

Decyzja	Kiedy	Domyślna rekomendacja agenta
Klucz API Databento + budżet danych	Tydzień 2→3	Konto + kredyty startowe; doładować
Akceptacja partii hipotecznych	Start każdej partii	Agent proponuje skład partii z uzasadnieniem
Otwarcie lockboxa dla kandydata	Po bramce 7.6	Tylko przy komplecie zielonych pól
GO/NO-GO na paper trading	Po lockboxie	Rekomendacja z pełnym raportem; decyzja
Konto IBKR paper + subskrypcja danych	Przed Etapem 5	–
Jakiegokolwiek realne pieniądze	Po kryteriach 11.4	Zawsze i wyłącznie user. Agent nie

14.4. Komunikacja

Rytm raportowania: **po każdej sesji roboczej** – aktualizacja statusu w PR (2–5 linii); **po każdej partii hipotecznej**

ROZDZIAŁ 15

Etyka, ograniczenia i uczciwość intelektualna

CZEGO TEN PROJEKT NIE OBIECUJE

- **Nie obiecuje zysku.** Rzetelny proces maksymalizuje szansę znalezienia prawdziwej przewagi i minimalizuje ryzyko strat.
- **Nie zastępuje decyzji właściciela kapitału.** Handel kontraktami futures niesie ryzyko straty przekraczające zysk.
- **Nie jest doradztwem inwestycyjnym.** To projekt badawczo-inżynierski prowadzony na zlecenie i rachunek.

Zobowiązania agenta: raportowanie wyników bez selekcji (wszystkie karty, nie tylko udane); przyznawanie się

ROZDZIAŁ 16

Następne kroki

16.1. Agent – pierwsza sesja robocza (natychmiast po zatwierdzeniu)

1. Struktura katalogów + `pyproject.toml` + konfiguracja `pytest` + `gitignore`.
2. `engine/sessions.py` i `engine/costs.py` z testami (niezależne od danych).
3. Rdzeń `engine/backtest.py` : pętla + pełna tabela rozstrzygnięć 5.4 + testy na spreparowanych barach.
4. `hypotheses/REGISTRY.md` z pełnym katalogiem v1.1: benchmarki B01–B04, karty przeformułowane H001–H004,
5. Commit, push, draft PR z opisem-statusem; raport dla usera.

16.2. User – dwie rzeczy, w kolejności

1. **Teraz:** konto na `databento.com` → klucz API przekazany jako zmienna środowiskowa sesji (nie plikiem w repo).
2. **Bez pośpiechu (przed Etapem 5):** konto paper IBKR; szczegóły konfiguracji API agent dostarczy, gdy będą gotowe.

16.3. Pierwsze partie badawcze

Po bramce „silnik udowodniony” (tydzień 4) projekt wchodzi w rytm partii:

- **Partia 0** (tydzień 5) – weryfikacja zaniku dryfu nocnego na własnych danych plus uruchomienie benchmarków

- **Partia 1** (tygodnie 6–7) – **H011, H005, H010**: karty o najniższym pokryciu z opublikowanymi strategiami.
- **Partia 2** (tygodnie 9–10) – **H013, H014, H016** z klasy K6, po zbudowaniu warstwy danych z 4.7.

Przed startem każdej partii agent przedstawia userowi finalne karty z wypełnionymi krokami 1–2 testu oryginalnego

ANEKS A

Wzory matematyczne – kompendium

A.1. Wyniki i oczekiwanie

$$R_i = P\&L_i / \text{ryzyko}_i \quad \cdot \quad E = (1/N) \cdot \sum R_i = p \cdot \bar{W} - (1-p) \cdot \bar{L} \quad \cdot \quad SE(E) = \sigma_R / \sqrt{N}$$

$$PF = \sum \text{zyski} / |\sum \text{straty}| \quad \cdot \quad MDE(N, \alpha=0.05) \approx 1.96 \cdot \sigma_R / \sqrt{N} \quad (\text{minimalny wykrywalny efekt})$$

$$\text{Liczność próby z mocą testu:} \quad N = ((z_{\alpha/2} + z_{\beta}) \cdot \sigma_R / E)^2$$

$$\text{moc 50\%: } N \approx 384 \quad \cdot \quad \text{moc 80\%: } N \approx 785 \quad \cdot \quad \text{moc 90\%: } N \approx 1051 \quad (\sigma_R = 1.2R, E = 0.12R)$$

Wersja 1.0 podawała tu wyłącznie rachunek istotności ($N \approx 384$), co odpowiada mocy 50%. σ_R estymujemy e

A.2. Sharpe i pochodne

$$SR_d = \text{mean}(r_d) / \text{std}(r_d) \quad \cdot \quad SR_{ann} = \sqrt{252} \cdot SR_d$$

Błąd standardowy SR (postać Mertensa, bez założenia normalności):

$$\sigma(SR_d) = \sqrt{(1 - \gamma_3 \cdot SR_d + ((\gamma_4 - 1)/4) \cdot SR_d^2) / (T - 1)}$$

Wersja 1.0 używała uproszczenia $\sqrt{((1 + SR^2)/2)/T}$, które zakłada normalność zwrotów i jest niespójne z mia

$$\text{Poprawka Lo (autokorelacja):} \quad SR_{adj} = SR_{ann} \cdot [1 + 2 \cdot \sum_{k=1..q} (1 - k/(q+1)) \cdot \rho_k]^{-1/2}$$

$$\text{Sortino} = \sqrt{252} \cdot \text{mean}(r_d) / \sqrt{(1/T) \cdot \sum \min(r_d, 0)^2} \quad \cdot \quad SQN = \sqrt{N} \cdot \text{mean}(R) / \text{std}(R)$$

A.3. Deflated Sharpe Ratio

$$SR_0 = \sigma_{SR} \cdot [(1-\gamma) \cdot \Phi^{-1}(1-1/N_{eff}) + \gamma \cdot \Phi^{-1}(1-1/(N_{eff} \cdot e))], \quad \gamma \approx 0.57722$$

$$DSR = \Phi(((SR-SR_0) \cdot \sqrt{(T-1)}) / \sqrt{(1 - \gamma_3 \cdot SR + ((\gamma_4-1)/4) \cdot SR^2)}) \rightarrow \text{wymagane} \geq 0.95$$

WARUNKI POPRAWNEJ IMPLEMENTACJI – DO SPRAWDZENIA W CODE REVIEW

1. **Częstotliwość dzienna.** SR, γ_3 i γ_4 liczone na dziennych zwrotach, nigdy annualizowane. Wstawienie SR
2. γ_4 to **kurtoza surowa** (rozkład normalny = 3), nie nadwyżkowa – spójnie z członem $((\gamma_4-1)/4)$.
3. $\sigma_{SR} = \sqrt{V[\{SR_n\}]}$ – odchylenie standardowe SR-ów w *poprzek zarejestrowanych prób*, zgodnie z *False Stra*

Algorytm wyznaczania N_{eff}

1. Zbierz krzywe dziennych zwrotów wszystkich zarejestrowanych wariantów: $R = \{r_1 \dots r_n\}$
2. Macierz korelacji $C = \text{corr}(R)$
3. Metryka odległości: $d_{ij} = \sqrt{0.5 * (1 - C_{ij})}$ ← nie surowa korelacja
4. Klastrowanie hierarchiczne (average linkage) na macierzy d
5. Liczba klastrow: algorytm ONC (López de Prado & Lewis) – wybór przez maksymalizację jakości podziału (silhouette), zamiast sztywnego progu
6. N_{eff} = liczba klastrow
7. SR wchodzące do SR_0 liczone z ZAGREGOWANYCH szeregów klastrow, nie z pojedynczych wariantów
8. Raport obowiązkowo zawiera analizę wrażliwości: N_{eff} dla odcięć 0.5-0.9
9. W razie wątpliwości – fallback konserwatywny: N_{eff} = surowa liczba prób

Wersja 1.0 przewidywała sztywne odcięcie korelacji na poziomie 0.7. Jest ono arbitralne: zbyt wysokie z

A.4. Monte Carlo

Bootstrap: $\{R^*_b\} \sim$ próbkowanie z $\{R_i\}$ ze zwracaniem, $B = 5000 \rightarrow CI_{95}(E) = [p_{2.5}, p_{97.5}]$

Bootstrap blokowy (syntetyki): bloki długości $L \sim \text{geometryczne}(1/\bar{L})$, $\bar{L} = 1$ dzień sesyjny

A.5. Sizing

kontrakty = $\lfloor \text{kapitał} \cdot f / (\text{stop_pkt} \cdot 2 \text{ USD}) \rfloor$, $f \in [0.0025, 0.005]$

weryfikacja: $f_{\text{kelly}}/4 > f$ wymagane (ćwierć-Kelly jako sufit bezpieczeństwa, nie cel)

ANEKS B

Karta kontraktu MNQ i kalendarz rolowań 2026–2027

Symbol / mnożnik / tick	MNQ · 2 USD × indeks · 0.25 pkt = 0.50 USD
Wartość 1 pkt / typowy dzienny zakres	2 USD · przy ATR ~250–400 pkt: 500–800 USD zakresu dzier
Godziny (ET)	Nd 18:00 → Pt 17:00, przerwa codzienna 17:00–18:00; RTH
Rozliczenie	Gotówkowe do SOQ; wygaśnięcie: 3. piątek H/M/U/Z

Kontrakt	Kod	Wygaśnięcie (3. piątek)	Orientacyjny roll wolumenowy
Wrzesień 2026	MNQU6	2026-09-18	~2026-09-10 (czwartek przed 2. piątkiem)
Grudzień 2026	MNQZ6	2026-12-18	~2026-12-10
Marzec 2027	MNQH7	2027-03-19	~2027-03-11
Czerwiec 2027	MNQM7	2027-06-18	~2027-06-10

Daty rolowania są orientacyjne – silnik wyznacza faktyczny dzień regułą wolumenową (4.3); tabela służy

ANEKS C

Kalendarz zdarzeń makro i sezonów wyników

Zdarzenie	Rytm	Godzina ET
CPI	miesięcznie, ~2. tydzień	08:30
NFP (payrolls)	1. piątek miesiąca	08:30
FOMC – decyzja + konferencja	8 posiedzeń/rok	14:00 + 14:30
PCE	koniec miesiąca	08:30
PPI / ISM / Michigan / JOLTS	miesięcznie	08:30 / 10:00
Wyniki big-tech (top-8 wag)	4x/rok/spółka; sezon: tyg. 3–6 po końcu kwartału	~16:05–17:00
OPEX (wygasanie opcji)	3. piątek miesiąca	–
Koniec miesiąca / kwartału	–	ostatnie sesje
Święta / dni skrócone	wg kalendarza CME	zamknięcie 13:00

ANEKS D

Szablony dokumentów roboczych

D.1. Karta hipotezy (hypotheses/Hxxx_nazwa.md)

```
# Hxxx – [nazwa]
Status: IDEA | TESTING | REJECTED(faza) | CANDIDATE | VALIDATED
Klasa mechanizmu: K1–K5 (min. 2)      Horyzont: intraday|event|swing
## Hipoteza (1 zdanie, falsyfikowalna)
## Mechanizm (dlaczego to miałoby istnieć i przetrwać)
## Warunek falsyfikacji (co dokładnie ją obala)
## Projekt eksperymentu (6.6)
    częstość sygnałów (szacunek): __/rok → N_00S ≈ __ ; MDE przy N: __ R
## Definicje operacyjne (wszystkie własne, jawne)
## Siatka parametrów (≤ 30 wariantów – wyliczyć!)
## Ryzyko crowdingu + wpływ na wykonanie
## Dziennik: [daty, decyzje, werdykty, odchylenia od planu]
```

D.2. Wpis REGISTRY.md

```
| Hxxx | hipoteza-1-zdanie | K_x | STATUS | werdykt: przyczyna + odsyłacz do raportu | n_wariantów |
```

D.3. Struktura raportu walidacyjnego (reports/Hxxx_validation.md)

1. Karta skrócona + konfiguracja (hash, zakres danych, koszty)
2. Eksploracja: rozkłady + testy istotności (wykresy)
3. IS: metryki + heatmapa siatki
4. 00S walk-forward: krzywa + metryki
5. MC ×3 (permutacja/bootstrap/syntetyki)
6. DSR (licznik globalny, N_eff, wynik)
7. Transfer NQ/ES + podokresy
8. Stress kosztów ×2
9. Bramka 7.6: checklist
10. Werdykt + wnioski W-xx

ANEKS E

Słownik pojęć PL/EN

Termin	Znaczenie w tym projekcie
ATR (Average True Range)	Średni prawdziwy zakres – miara zmienności; używana wyłącznie w f
Back-adjustment	Korekta historycznych cen kontraktu ciągłego o spready rolowań (4
Blackout window	Okno wokół zdarzenia rangi 1, w którym silnik nie otwiera pozycji
Bracket order	Zlecenie wejścia z automatycznie dowiązaniem stopem i celem.
Crowding	Zatłoczenie strategii – degradacja przewagi przez masowe handlowa
DSR (Deflated Sharpe Ratio)	Sharpe „odparowany” z premii za wielokrotne testowanie (6.5, A.3)
Edge / przewaga	Dodatnie oczekiwanie po kosztach, potwierdzone 00S, z mechanizmem
ETH / RTH	Electronic/Regular Trading Hours – sesja całodobowa vs 09:30–16:0

Expectancy (E)	Średni wynik transakcji w R.
IB / Initial balance	Zakres pierwszych X minut RTH.
IS / OOS	In-sample (dane do budowy) / out-of-sample (dane do uczciwego testu)
Lockbox / sejf	Nietykalna końcówka historii do jednorazowej finalnej weryfikacji
Lookahead bias	Przeciek informacji z przyszłości do decyzji – architektonicznie
MDD	Maksymalne obsunięcie krzywej kapitału.
MOC (Market-on-Close)	Zlecenia na zamknięcie; publikacja nierównowagi od 15:50 ET (H012)
ON-range	Zakres sesji nocnej 18:00–09:30 ET.
OPEX	Wygasanie opcji, 3. piątek miesiąca.
PDH / PDL / PDC	Poprzednie dzienne high / low / close (na trade_date).
PF (Profit factor)	Suma zysków / suma strat.
Purging / embargo	Usuwanie buforów danych wokół granic okien walidacji (7.3).
R	Jednostka ryzyka pojedynczej transakcji (10.2).
Slippage / poślizg	Różnica między ceną modelową a wykonania (5.5).
SOQ	Special Opening Quotation – kurs rozliczenia wygasających kontraktów
Tracking error	Rozjazd wyników live vs symulacja tego samego okresu (11.3).
Trial counter / licznik prób	Globalny licznik wszystkich wariantów backtestów projektu – wejście
VWAP	Volume-Weighted Average Price – średnia cena ważona wolumenem sesji
Walk-forward	Sekwencyjna walidacja: optymalizacja na oknie IS, test na następnym

CHANGELOG

Wersja 1.0 → 1.1: co zmieniły audyty

Dokument w wersji 1.0 został poddany **czterem niezależnym audytom zewnętrznym**. Poniżej pełny wykaz – zarówno

Zmiany o największym znaczeniu

Obszar	Na czym polegał problem i co zmieniono
Definicja oryginalności rozd. 8.4	Reguła „dwie niezależne klasy mechanizmów = oryginalność” była fałs
Nieprzechodnia bramka rozd. 1.3, 6.5	Kombinacja „ $\text{Sharpe} \geq 0.8 + \text{DSR} > 0.95$ ” była matematycznie nieosiąga
Katalog hipotez rozd. 9	Cztery karty okazały się tożsame z opublikowanymi setupami – przeni
Skrzywienie barów spornych rozd. 5.4	Reguła „SL wygrywa” nie jest neutralnym konserwatyzmem, lecz skrzyw
Błąd w kosztach rozd. 3.2	Podany koszt 3.20 USD round-turn był niespójny z własnym wzorem (1.

Pełny wykaz przyjętych poprawek

Rozdział	Zmiana
1.3	System dwustopniowy; $DSR \geq 0.95$ zamiast pustego „ $DSR > 0$ ”; podłoga transakcji 300 → 4
1.4	Dopisane decyzje: baza kosztów, bramka sukcesu, zakres danych K6
2.2	Dodana szósta klasa mechanizmu K6 – transmisja międzyrynkowa, basis, price discovery
3.2	Korekta arytmetyczna kosztów; tabela wrażliwości kosztów rocznych; potwierdzenie prow
4.1	Realny koszt danych (25–60 USD, pokryty kredytami); zakaz używania continuous bez bac
4.2	Klasyfikacja luk expected vs anomaly; zakaz forward-fill dla barów wykonania
4.3	Rozdzielenie serii: poziomy międzysesyjne na cenach surowych, P&L na skorygowanych
4.6	Sanity-report przebudowany pod semantykę braku barów; historyczna przerwa 2019–2021;
4.7	<i>Nowy podrozdział</i> – dane uzupełniające dla klasy K6 w wersji oszczędnej
5.4	Rozstrzyganie sub-barami 1 s; pasmo wrażliwości; poślizg stopa skalowany wielkością 1
5.5	Model poślizgu skalowany zmiennością zamiast statycznej tabeli
5.6	Nowe testy silnika: rozdzielenie serii, zakaz wykonania przy zerowym wolumenie
6.4	Dodany człon mocy testu; wyjaśnienie różnicy istotność vs moc; empiryczna estymacja c
6.5	Tabele wykonalności DSR; trzy warunki poprawnej implementacji; limit 10 wariantów; ka
7.1	Dodane CPCV jako bramka przed lockboxem; DSR liczone na pełnym zszytym OOS
7.2	Bootstrap blokowy; 1000 serii syntetycznych z równym budżetem prób; dodane PBO/CSCV i
7.3	Purging i embargo rozszerzone na strategię intraday (≥ 60 min)
7.6	Bramka rozbita na dwie listy kontrolne – Tier 1 i Tier 2
8.1	Cykl życia hipotezy z nowym stanem PROMISING i pętlą paper tradingu
8.4	<i>Przepisany od zera</i> – czterokrokowy test oryginalności
8.5	Limit siatki 30 → 10 wariantów; limit partii 120 → 40
9	<i>Przebudowany</i> – benchmarki B01–B04, karty przeformułowane, kandydaci z klasy K6, obowi
11.1	Koszt danych ~10 USD; oficjalne ograniczenia symulatora; zmniejszenie konta paper; pr
11.2	Agregacja barów 5 s; idempotentny menedżer zleceń; ryzyka biblioteki i testy chaosu
11.3	Pięć rozdzielonych serii metryk; twarde kryterium poślizgu stopów
11.4	Dodane kryteria: DSR łączne, poślizg stopów, zgodność barów; wyliczenie długości pape
13.1	<i>Nowa sekcja</i> – czternaście ryzyk technicznych stacku
A.1	Wzór na licznosc próby z członem mocy testu
A.2	Błąd standardowy SR w postaci Mertensa zamiast wersji zakładającej normalność
A.3	Algorytm wyznaczania N_{eff} (ONC, metryka odległości, analiza wrażliwości); warunki in

Uwagi odrzucone lub zawężone

Uwaga audytu	Decyzja
Wnioskowanie kolejności zdarzeń w barze z położenia ceny otwarcia względem ekstremów	Odrzucone
VWAP musi być liczony na serii surowej	Zawężone
Warunek kolejkowy dla zleceń z limitem (wolumen na poziomie > kolejka przed nami)	Odrzucone
Progi Sharpe 1.5–2.0 jako wymóg dla intraday	Zawężone
Zanik dryfu overnight jako fakt ustalony	Do weryfikacji
Mechaniczne stosowanie średniego zaniku po publikacji do wszystkich efektów	Odrzucone

BILANS

46 zmian wprowadzonych, **6 uwag odrzuconych lub zawężonych**, jeden konflikt między audytami rozstrzygnięty

Dwie korekty okazały się korzystne finansowo: dane historyczne mieszczą się w kredytach startowych, a su

Projekt „G” · Dokument założycielski v1.1 · 31 lipca 2026 · Wygenerowano w repozytorium lippaol-art/G.

Wersja 1.1 uwzględnia wyniki czterech niezależnych audytów zewnętrznych (metodologia backtestingu, aparat

Dokument badawczo-inżynierski; nie stanowi doradztwa inwestycyjnego. Handel kontraktami futures wiąże się